Differential Gene Expression and Pathway Enrichment in Lung Adenocarcinoma (GSE10072) with Up- and Down-regulated Gene Analysis in R

By Syamsul Arif Ardiansyah

Pendahuluan

Analisis ekspresi gen merupakan pendekatan penting untuk memahami perubahan molekuler yang terjadi antara kondisi biologis berbeda, seperti jaringan kanker dan normal. Dataset publik GSE10072 menyediakan data mikroarray dari adenokarsinoma paru-paru dan jaringan paru normal, sehingga memungkinkan identifikasi gen-gen yang secara signifikan diubah. Melalui analisis differential expression dengan limma, gen-gen yang up-regulated maupun down-regulated dapat dipisahkan, memberi gambaran lebih spesifik mengenai jalur biologis yang diaktifkan atau ditekan.

Selain itu, pemanfaatan analisis pathway seperti Gene Ontology (GO) dan KEGG memungkinkan penilaian terhadap proses biologis dan jalur metabolik yang terkait dengan gen-gen signifikan tersebut. Visualisasi data melalui heatmap, UMAP, dotplot, dan network plot memperkuat interpretasi pola ekspresi gen serta pathway terkait. Dengan pendekatan ini, analisis data ekspresi gen dapat dilakukan secara menyeluruh di R, mulai dari preprocessing, anotasi gen, hingga interpretasi hasil enrichment pathway.

Metode

1. Pengambilan Data dan Preprocessing

Dataset GSE10072 (Lung Adenocarcinoma vs Normal) diunduh dari (GEO) menggunakan package GEOquery di R dengan opsi GSEMatrix = TRUE dan AnnotGPL = TRUE untuk mengambil data dalam format ExpressionSet sekaligus anotasi gen. Matriks ekspresi gen diambil dengan fungsi exprs(). Preprocessing dilakukan dengan log2-transformasi. Probe yang tidak memiliki simbol gen dihapus, dan probe yang mengkode gen sama di-collapse menjadi level gen menggunakan fungsi avereps(), sehingga setiap gen unik hanya muncul satu kali. Matriks ekspresi hasil collapse (ex_gene) kemudian digunakan untuk analisis downstream.

2. Definisi Kelompok Sampel dan Desain Statistik

Kelompok sampel didefinisikan berdasarkan metadata source_name_ch1 pada ExpressionSet, dikonversi menjadi faktor di R. Matriks desain dibuat menggunakan model.matrix(~0 + group) tanpa intercept, sesuai praktik terbaik limma. Kontras biologis yang dianalisis adalah kanker vs normal, yang diterapkan menggunakan makeContrasts() dan contrasts.fit().

3. Analisis Differential Expression

Analisis differential expression dilakukan pada level gen menggunakan paket limma. Model linear diterapkan (lmFit), kemudian kontras diterapkan (contrasts.fit) dan stabilisasi varians dilakukan dengan eBayes. Gen yang signifikan diambil menggunakan topTable() dengan koreksi FDR (adjust = "fdr") dan p-value cutoff 0.01. Hasil DEG disusun berdasarkan nilai adjusted p-value dan log fold change.

4. Visualisasi Distribusi Ekspresi dan Pola Sampel

Distribusi nilai ekspresi antar sampel divisualisasikan dengan boxplot dan density plot. Reduksi dimensi dilakukan menggunakan UMAP (umap package) untuk menampilkan pemisahan sampel secara global berdasarkan ekspresi gen, sedangkan pola ekspresi gen signifikan divisualisasikan menggunakan heatmap (pheatmap) pada top 50 gen dengan variansi tertinggi.

5. Volcano Plot

Volcano plot dibuat untuk menampilkan gen-gen up- dan down-regulated berdasarkan log fold change dan adjusted p-value, dengan ambang batas logFC > 1 atau < -1 dan adj.P.Val < 0.01. Status gen dikategorikan menjadi UP, DOWN, atau NO significant.

6. Analisis Enrichment Pathway

Gen signifikan (top 50) dikonversi dari SYMBOL ke ENTREZID menggunakan bitr() (package clusterProfiler). Analisis enrichment dilakukan pada: Gene Ontology (GO) – Biological Process (BP) menggunakan enrichGO(). KEGG Pathway menggunakan enrichKEGG() Enrichment dilakukan juga secara terpisah untuk gen up-regulated dan down-regulated, sehingga dapat menilai jalur biologis yang spesifik untuk masing-masing kategori. Visualisasi dilakukan menggunakan dotplot().

7. Output dan Ekspor Data

Hasil analisis DEG, GO, dan KEGG diekspor ke file Excel (openxlsx) dengan beberapa sheet:

a) Top50 DEG
b) GO enrichment
c) KEGG enrichment
d) UP-regulated genes + GO/KEGG
e) DOWN-regulated genes + GO/KEGG

Setiap sheet berisi kolom penting seperti SYMBOL, logFC, p-value, adj.P.Val, dan hasil enrichment.

Hasil dan Interpretasi

Dalam studi ini, dilakukan analisis dataset GSE10072 yang berfokus pada Lung Adenocarcinoma dibandingkan dengan jaringan normal menggunakan platform microarray Affymetrix GPL96. Data awal diolah dengan transformasi log2 untuk menstabilkan varians dan menormalkan distribusi ekspresi gen. Selanjutnya, analisis diferensial ekspresi dilakukan menggunakan pendekatan limma, sehingga gen-gen yang menunjukkan perbedaan signifikan antara kondisi kanker dan normal dapat diidentifikasi. Untuk mengurangi redundansi probe yang merepresentasikan gen yang sama, dilakukan collapsing ke level gen, sehingga setiap gen hanya muncul sekali dengan nilai paling signifikan. Gen-gen yang teridentifikasi kemudian dikategorikan menjadi upregulated dan downregulated, dan dilakukan analisis enrichment fungsional menggunakan Gene Ontology (GO) dan KEGG Pathway.

Boxplot

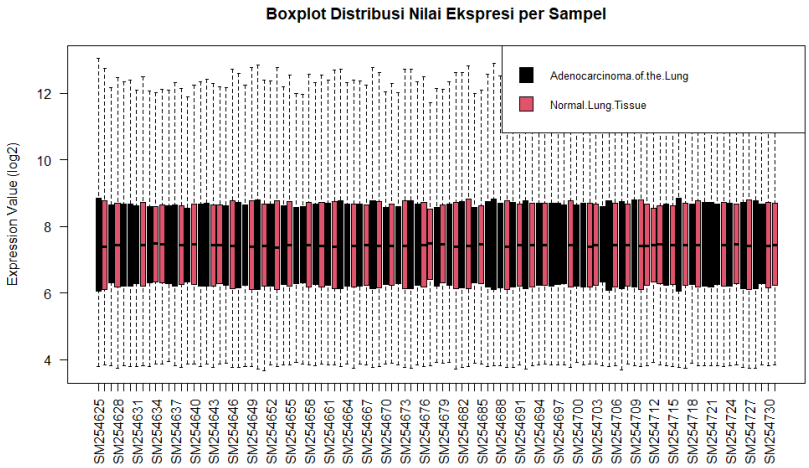

Distribusi nilai ekspresi gen

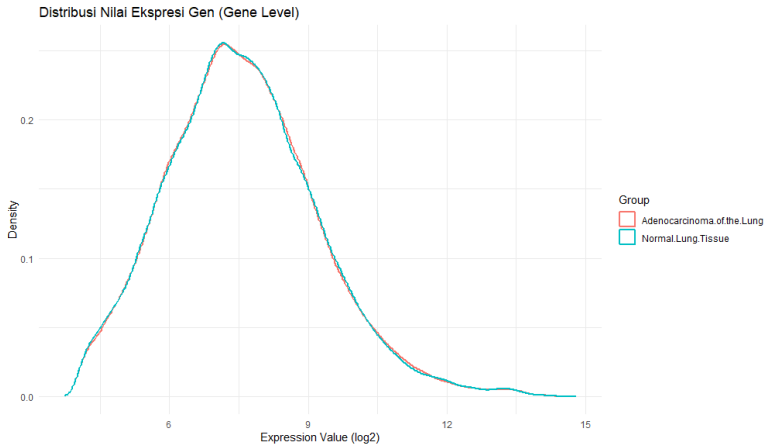

UMAP

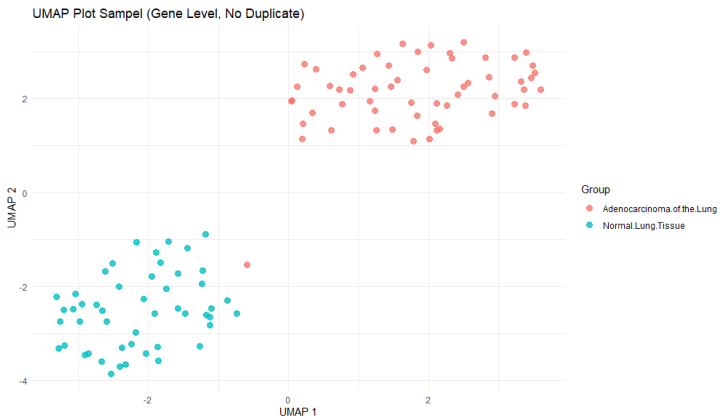

Volcano Plot

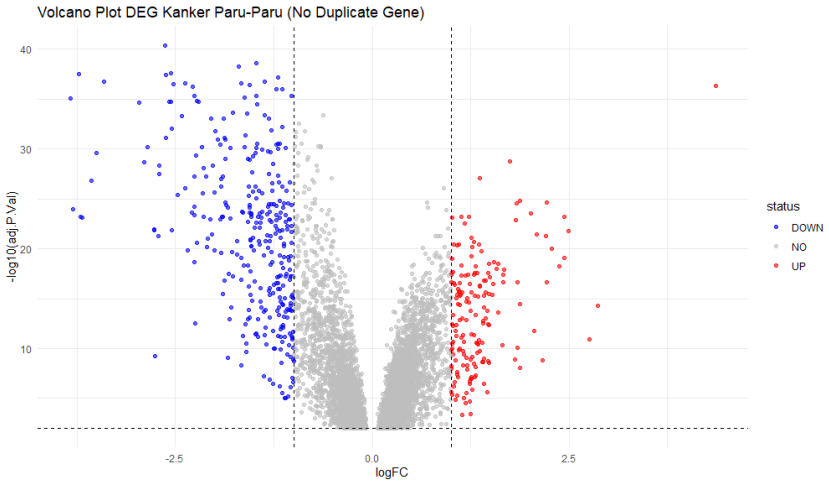

Heatmap

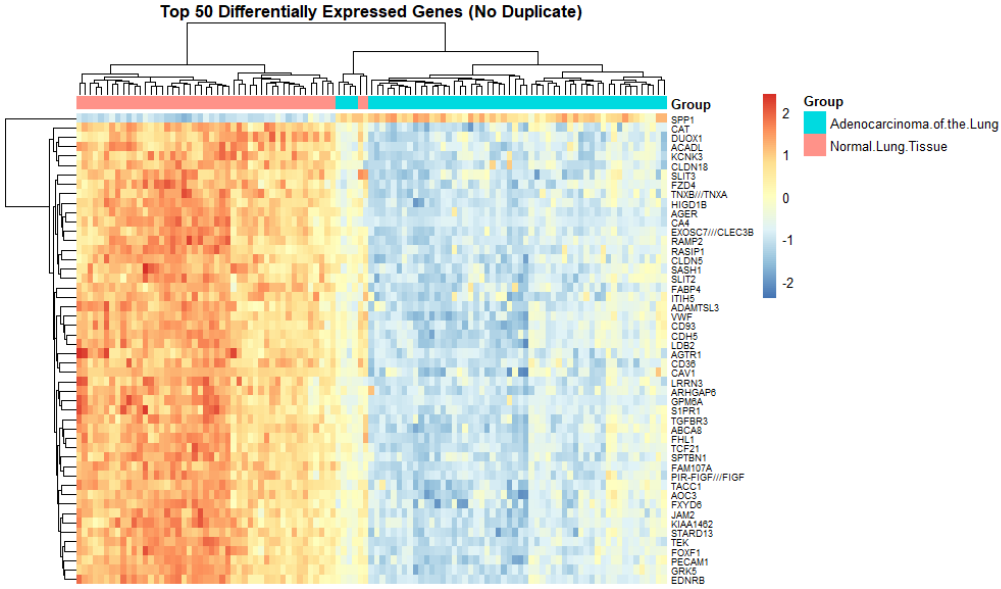

GO dotplot top 50 gen

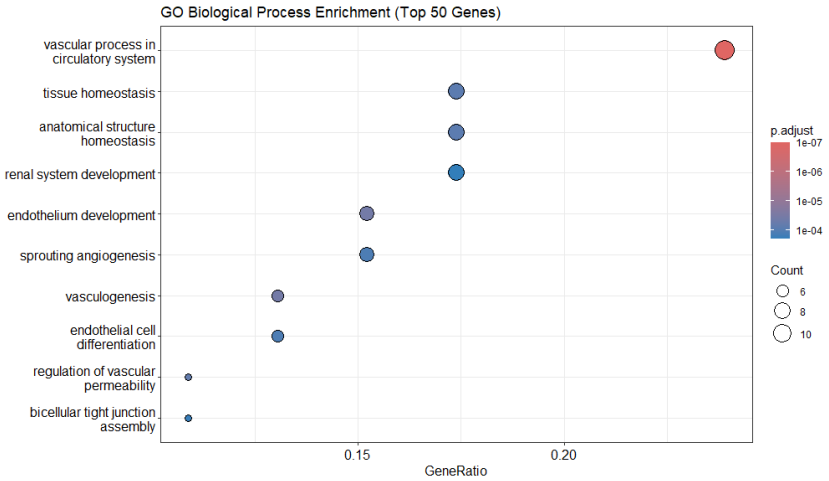

KEGG Dotplot top 50 gen

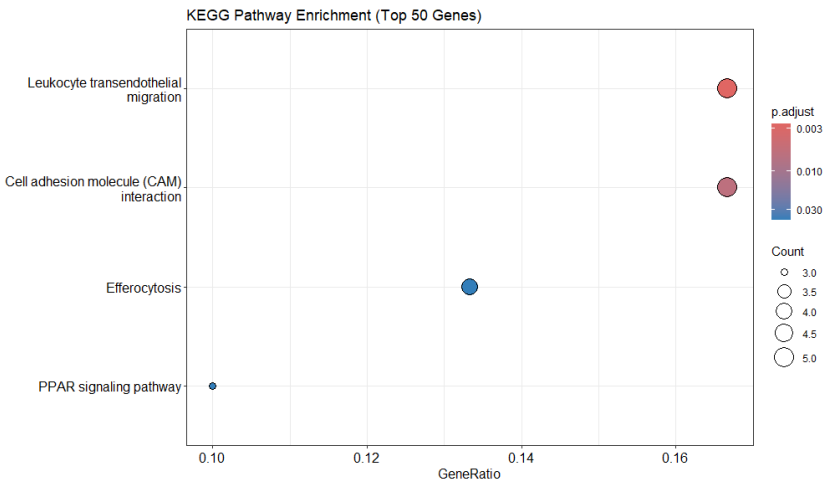

GO dotplot up gen

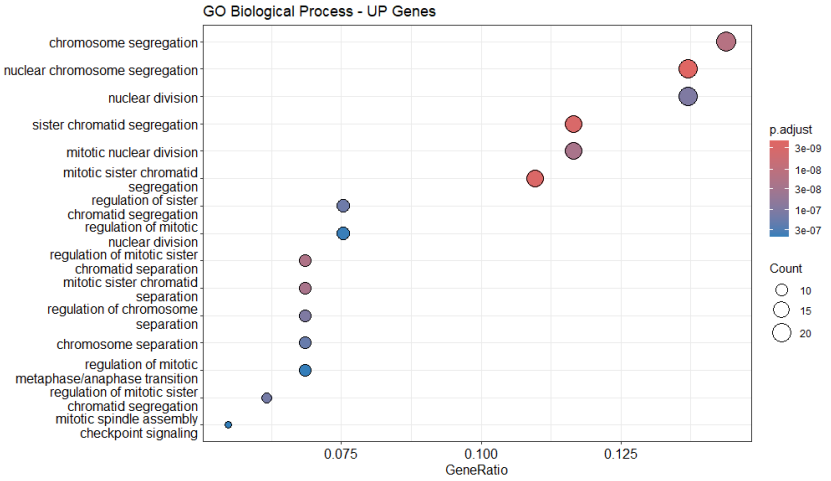

GO dotplot down gen

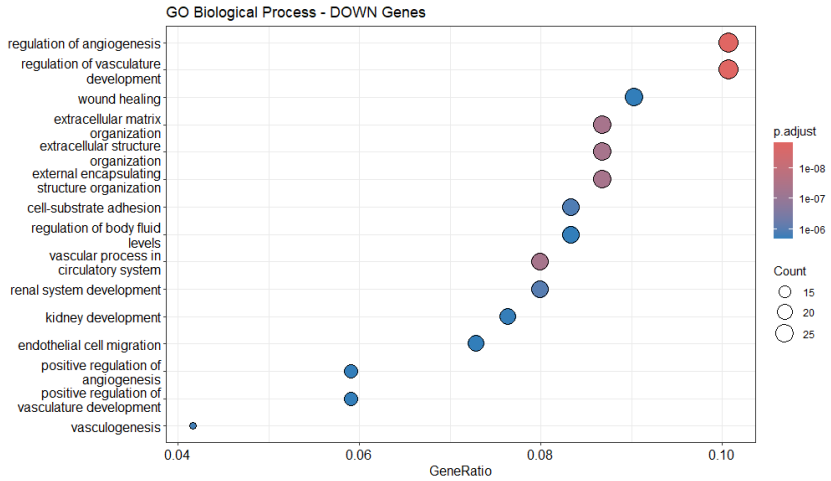

KEGG Dotplot up gen

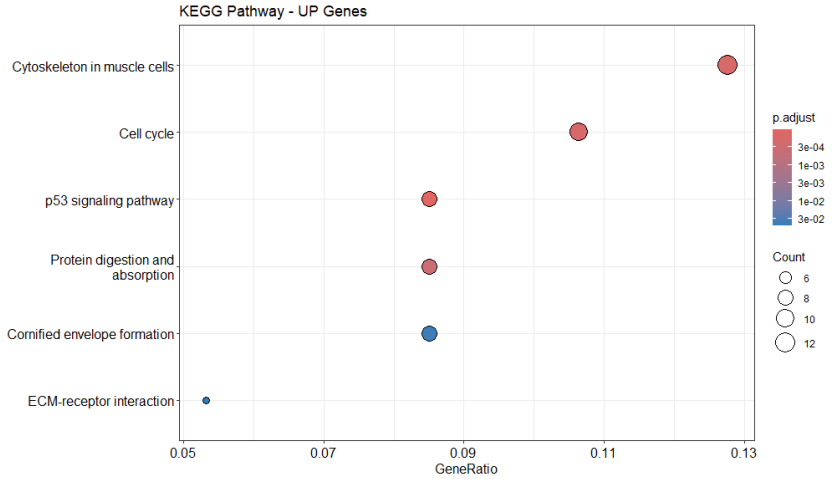

KEGG Dotplot down gen

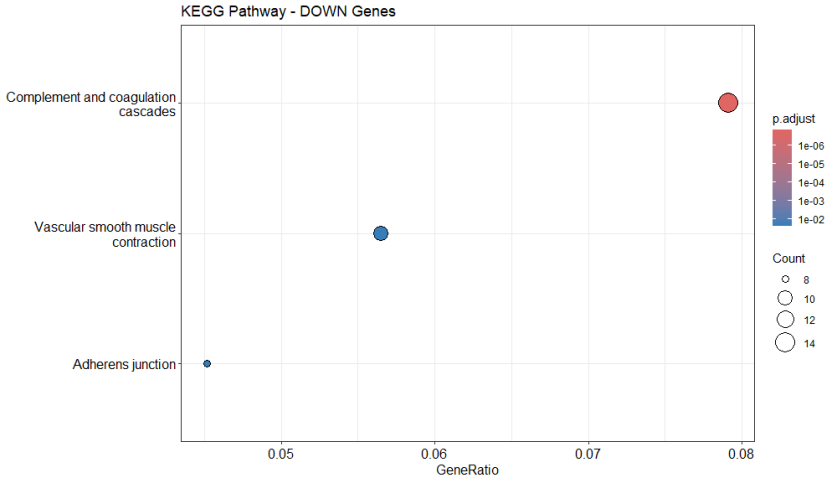

Berdasarkan tabel Top 50 Gen Signifikan, terlihat bahwa pola utama fungsi biologis gen-gen tersebut sangat kuat terkait dengan proses vaskular, angiogenesis, adhesi sel, serta regulasi siklus sel. Banyak gen seperti FAM107A, GRK5, CD36, CDH5, TEK, dan PECAM1 berasosiasi dengan proses vascular process in circulatory system, vasculogenesis, endothelial development, sprouting angiogenesis, hingga vascular permeability, yang menunjukkan bahwa perubahan ekspresi gen kemungkinan besar berhubungan dengan dinamika pembentukan dan fungsi pembuluh darah. Selain itu, pengayaan GO pada gen yang meningkat (upregulasi) didominasi oleh proses mitotic nuclear division, chromosome segregation, sister chromatid segregation, dan checkpoint pembelahan sel, yang mengindikasikan adanya peningkatan aktivitas proliferasi atau pembelahan sel.

Sebaliknya, gen yang mengalami penurunan ekspresi (downregulasi) terutama terlibat dalam regulation of angiogenesis, extracellular matrix organization, extracellular structure organization, vasculature development, wound healing, dan proses adhesi sel seperti cell-substrate adhesion. Hal ini menunjukkan kemungkinan terjadinya penurunan remodeling matriks ekstraseluler dan regulasi pembentukan pembuluh darah. Dari sisi jalur molekuler, analisis KEGG menunjukkan bahwa gen upregulasi berkaitan dengan p53 signaling pathway, cell cycle, cytoskeleton organization, yang mendukung peran proliferasi dan kontrol siklus sel, sedangkan gen downregulasi banyak terkait dengan complement and coagulation cascades, vascular smooth muscle contraction, adherens junction, yang mengarah pada perubahan fungsi vaskular, integritas jaringan, dan respon inflamasi.

Secara kuantitatif, jumlah gen yang mengalami penurunan ekspresi (317 gen) lebih besar dibandingkan gen yang meningkat (171 gen), menunjukkan adanya kecenderungan supresi pada jalur terkait angiogenesis, matriks ekstraseluler, dan fungsi vaskular. Secara keseluruhan, profil ini mengindikasikan bahwa sistem biologis yang dianalisis kemungkinan mengalami peningkatan aktivitas proliferasi sel namun disertai penurunan regulasi struktur jaringan dan fungsi vaskular, yang sering dikaitkan dengan proses remodeling jaringan, stres seluler, atau kondisi patologis tertentu seperti hipoksia, inflamasi kronis, atau progresi penyakit vaskular/tumor.

Kesimpulan

Berdasarkan hasil analisis Gen Set pada dataset GSE kanker paru menggunakan R, yang meliputi visualisasi boxplot, volcano plot, UMAP, serta analisis fungsional GO dan KEGG, dapat disimpulkan bahwa data memiliki kualitas normalisasi yang baik dan mampu memisahkan kelompok sampel secara jelas. Boxplot menunjukkan distribusi ekspresi gen yang sudah seragam setelah normalisasi, sementara volcano plot mengidentifikasi gen-gen yang berbeda signifikan antara kelompok dengan pola upregulasi dan downregulasi yang jelas. Visualisasi UMAP memperlihatkan pemisahan klaster sampel yang menunjukkan perbedaan profil ekspresi gen antar kondisi. Analisis fungsional GO dan KEGG menunjukkan bahwa gen-gen signifikan terutama terlibat dalam proses proliferasi sel, regulasi siklus sel, angiogenesis, adhesi sel, serta organisasi matriks ekstraseluler. Secara umum, seluruh tahapan analisis berhasil menggambarkan pola ekspresi gen, perbedaan biologis antar kelompok, serta fungsi molekuler utama yang terkait, sehingga menunjukkan bahwa workflow analisis Gen Set pada dataset GSE menggunakan R telah berjalan dengan baik dan dapat digunakan untuk interpretasi biologis dasar.

Lampiran

- Excel data top 50 gen signifikan beserta analisis enrichment
- Excel data gen upregulasi dan downregulasi analisis enrichment
- Markdown script R
- Di upload di GitHub (https://github.com/syamsulaar/Bioinformatik/tree/Omics_Lite)