Integrated Analysis of Differential Gene Expression, Functional Enrichment, and Gene Set Enrichment Reveals Molecular Mechanisms in Breast Cancer Subtypes

By Syamsul Arif Ardiansyah

Pendahuluan

Kanker payudara merupakan penyakit yang bersifat heterogen dan terdiri atas beberapa subtipe molekuler, seperti Luminal A, Luminal B, HER2-positive, dan Triple-Negative Breast Cancer (TNBC), yang memiliki karakteristik biologis, tingkat proliferasi, serta respons terapi yang berbeda. Perbedaan tersebut mencerminkan adanya variasi perubahan genetik dan pola ekspresi gen yang mendasari masing-masing subtipe. Oleh karena itu, pendekatan berbasis analisis ekspresi gen menjadi penting untuk memahami mekanisme molekuler yang terlibat dalam perkembangan kanker payudara, serta untuk mengidentifikasi gen dan jalur biologis yang berpotensi menjadi biomarker maupun target terapi yang lebih spesifik.

Dalam project ini dilakukan analisis komparatif terhadap dua dataset mikroarray independen, yaitu GSE65194 dan GSE45827, untuk mengidentifikasi gen yang mengalami perubahan ekspresi secara konsisten pada berbagai subtipe kanker payudara. Analisis diawali dengan evaluasi kualitas dan distribusi data ekspresi gen melalui visualisasi statistik serta analisis reduksi dimensi menggunakan Uniform Manifold Approximation and Projection (UMAP) untuk melihat pola pengelompokan sampel berdasarkan profil ekspresi gen. Selanjutnya dilakukan identifikasi differentially expressed genes (DEGs) pada masing-masing subtipe, diikuti dengan analisis irisan gen antar subtipe serta analisis overlap antar dataset guna memperoleh gen yang konsisten muncul pada kedua dataset.

Gen-gen yang teridentifikasi kemudian dianalisis lebih lanjut menggunakan pendekatan functional enrichment, yaitu Gene Ontology (GO) dan Kyoto Encyclopedia of Genes and Genomes (KEGG), untuk mengidentifikasi proses biologis dan jalur molekuler yang berperan dalam perkembangan tumor. Selain analisis berbasis gen signifikan, project ini juga menerapkan Gene Set Enrichment Analysis (GSEA) untuk mengevaluasi kecenderungan aktivasi atau penekanan jalur biologis secara global berdasarkan seluruh distribusi data ekspresi gen. Pendekatan ini memungkinkan identifikasi pathway yang berkaitan dengan proliferasi sel, siklus sel, metabolisme, maupun interaksi sel dengan lingkungan mikro tumor pada masing-masing subtipe kanker payudara. Melalui integrasi berbagai pendekatan analisis bioinformatika tersebut, project ini diharapkan dapat memberikan gambaran yang lebih komprehensif mengenai karakteristik molekuler setiap subtipe kanker payudara serta mengidentifikasi gen dan jalur biologis yang berpotensi berperan penting dalam patogenesis penyakit.

Metode

1. Akuisisi Dataset Ekspresi Gen

Data ekspresi gen diperoleh dari basis data publik Gene Expression Omnibus (GEO). Dua dataset yang digunakan adalah GSE65194 dan GSE45827, yang diunduh menggunakan paket GEOquery dalam lingkungan R (Bioconductor). Data diakses dalam format ExpressionSet yang mencakup matriks ekspresi gen (exprs()), metadata sampel (pData()), dan anotasi fitur/probe (fData()).

2. Pre-processing dan Transformasi Data

Matriks ekspresi diekstraksi dari masing-masing ExpressionSet. Distribusi data diperiksa menggunakan nilai untuk menentukan kebutuhan transformasi log2. Apabila rentang nilai ekspresi menunjukkan karakteristik data belum terlogaritma (nilai maksimum tinggi dan rentang distribusi lebar), maka dilakukan transformasi log2 setelah mengganti nilai ≤0 menjadi NA. Prosedur ini dilakukan secara independen pada kedua dataset untuk memastikan normalisasi skala data sebelum analisis lanjutan.

3. Anotasi dan Kolaps Probe ke Tingkat Gen

Karena platform mikroarray menggunakan beberapa probe untuk satu gen, dilakukan proses pembersihan dan penggabungan (collapse) probe menjadi satu representasi per gen sebagai berikut:

- Simbol gen diekstraksi dari metadata fitur.
- Jika satu probe memiliki lebih dari satu simbol gen (dipisahkan dengan "///"), hanya simbol pertama yang digunakan.
- Spasi berlebih dihapus dan entri kosong atau NA dieliminasi.
- Probe dengan simbol gen valid dipertahankan.
- Ekspresi dari beberapa probe yang memetakan gen yang sama digabung menggunakan fungsi avereps (rata-rata nilai ekspresi).

Hasil akhir berupa matriks ekspresi tingkat gen tanpa duplikasi simbol gen.

4. Definisi dan Seleksi Kelompok Sampel

Metadata sampel digunakan untuk mengelompokkan subtipe molekuler kanker payudara berdasarkan informasi

pada kolom source_name_ch1. Pada dataset GSE65194 dipilih dan disederhanakan menjadi: LuminalA, LuminalB, HER2, TNBC, dan Normal. Pada dataset GSE45827, dipilih Label diseragamkan menjadi: LuminalA, LuminalB, HER2, Basal, dan Normal.

5. Penyusunan Design Matrix dan Kontras

Model linier disusun menggunakan pendekatan tanpa intersep (~0 + group) sehingga setiap subtipe memiliki kolom tersendiri dalam design matrix. Kontras dibuat untuk membandingkan masing-masing subtipe terhadap kelompok Normal:

- LuminalA vs Normal
- LuminalB vs Normal
- HER2 vs Normal
- TNBC/Basal vs Normal

Pendekatan ini diterapkan secara terpisah pada kedua dataset.

6. Analisis Ekspresi Diferensial

Analisis ekspresi diferensial dilakukan menggunakan paket limma melalui tahapan:

- Linear model fitting (lmFit)
- Penerapan matriks kontras (contrasts.fit)
- Moderasi varians dengan metode Empirical Bayes (eBayes)

Gen dengan nilai adjusted p-value (FDR) < 0,01 dipertimbangkan sebagai gen yang berbeda bermakna. Koreksi multipel dilakukan menggunakan metode False Discovery Rate (FDR). Hasil analisis diekstraksi untuk masing-masing subtipe dibandingkan dengan Normal, dan simbol gen ditambahkan berdasarkan nama baris matriks ekspresi yang telah dikolaps pada tingkat gen.

7. Evaluasi Kualitas Data Ekspresi

Evaluasi distribusi data dilakukan pada dataset GSE65194 dan GSE45827 menggunakan boxplot dan density plot. Boxplot dibuat setelah pengurutan sampel berdasarkan kelompok biologis untuk menilai konsistensi distribusi nilai ekspresi log2 antar sampel dan antar subtipe. Outlier tidak ditampilkan guna memudahkan evaluasi median dan sebaran antar kelompok. Density plot dibangun menggunakan pendekatan distribusi kernel untuk seluruh nilai ekspresi gen dalam masing-masing kelompok. Visualisasi ini bertujuan memastikan keseragaman distribusi global setelah proses normalisasi dan transformasi log2.

8. Analisis Dimensionality Reduction (UMAP)

Untuk mengevaluasi pola pengelompokan sampel secara global, dilakukan analisis Uniform Manifold Approximation and Projection (UMAP). Matriks ekspresi gen (tingkat gen) ditranspos sehingga baris merepresentasikan sampel. Analisis dilakukan dengan seed tetap untuk menjamin reprodusibilitas. Plot dua dimensi (UMAP1 dan UMAP2) divisualisasikan menggunakan ggplot2 dengan pewarnaan berdasarkan subtipe molekuler. Pendekatan ini digunakan untuk menilai pemisahan biologis antar kelompok tumor dan jaringan normal pada masing-masing dataset.

9. Gen Ekspresi Diferensial (Volcano Plot)

Volcano plot dibuat untuk setiap perbandingan subtipe terhadap Normal pada kedua dataset. Kriteria klasifikasi gen:

- Upregulated (UP): log2 Fold Change > 1 dan FDR < 0,01
- Downregulated (DOWN): log2 Fold Change < −1 dan FDR < 0,01
- Non-signifikan (NO): tidak memenuhi kriteria di atas

Garis batas vertikal (|log2FC| = 1) dan horizontal (FDR = 0,01) ditambahkan untuk memperjelas ambang signifikansi. Visualisasi ini digunakan untuk menggambarkan distribusi dan proporsi gen yang mengalami perubahan ekspresi bermakna pada masing-masing subtipe.

10. Ekstraksi dan Ekspor Differentially Expressed Genes (DEG)

Gen signifikan difilter berdasarkan kriteria:

- |log2FC| > 1
- Adjusted p-value (FDR) < 0,01

Gen yang memenuhi kriteria diklasifikasikan sebagai UP atau DOWN. Hasil DEG untuk setiap subtipe diekspor dalam format Microsoft Excel (.xlsx), dengan satu lembar kerja untuk masing-masing subtipe pada setiap dataset.

11. Analisis Venn Diagram

Sebagai visualisasi komplementer, dibuat diagram Venn empat kelompok untuk masing-masing dataset, mencakup ALL DEG, UP-regulated genes, DOWN-regulated genes. Diagram disimpan dalam resolusi tinggi (300 dpi).

12. Ekstraksi Irisan Eksklusif (Exclusive Intersection)

Untuk analisis yang lebih rinci, dibuat fungsi khusus untuk menghitung irisan eksklusif antar kombinasi subtipe. Pendekatan ini:

- Menghasilkan seluruh kombinasi kemungkinan antar subtipe.
- Mengambil gen yang muncul pada kombinasi tertentu.
- Menghilangkan gen yang juga muncul pada subtipe lain di luar kombinasi tersebut.

Hasilnya disusun dalam matriks dengan kolom merepresentasikan kombinasi subtipe dan diekspor ke format Excel untuk analisis lanjutan

13. Perbandingan Antar Dua Dataset

Pada tahap ini dilakukan perbandingan hasil antara dua dataset independen, yaitu GSE65194 dan GSE45827. Tujuan utama tahap ini adalah mengidentifikasi gen-gen yang muncul secara konsisten pada kedua dataset. Gen

yang ditemukan pada dua kohort berbeda dianggap lebih stabil dan memiliki kemungkinan lebih besar berperan penting secara biologis, dibandingkan gen yang hanya muncul pada satu dataset saja. Analisis dilakukan untuk masing-masing subtipe kanker payudara, meliputi: TNBC, Luminal A, Luminal B, HER2. Gen dikelompokkan menjadi: Seluruh gen signifikan, Gen yang meningkat ekspresinya (upregulated), Gen yang menurun ekspresinya (downregulated). Hasil perbandingan ini menghasilkan daftar gen yang: Konsisten di kedua dataset, Spesifik pada dataset tertentu. Pendekatan ini bertujuan meningkatkan validitas temuan dan mengurangi kemungkinan hasil yang bersifat kebetulan.

14. Analisis Fungsi Biologis (GO dan KEGG)

Setelah diperoleh gen yang konsisten pada kedua dataset, dilakukan analisis untuk memahami peran biologisnya. Analisis ini bertujuan untuk mengetahui proses biologis dan jalur molekuler yang dipengaruhi oleh gen. Interpretasi dilakukan berdasarkan dua pendekatan utama: Proses biologis (Gene Ontology), Jalur sinyal atau pathway (KEGG). Dengan demikian, analisis tidak hanya berhenti pada daftar gen, tetapi berkembang menjadi pemahaman terhadap konteks biologisnya.

15. Analisis Berbasis Seluruh Gen (Gene Set Enrichment Analysis / GSEA)

Selain menganalisis gen yang telah melewati batas signifikansi tertentu, anaisis ini juga menggunakan pendekatan Gene Set Enrichment Analysis (GSEA) untuk mengevaluasi perubahan ekspresi gen secara lebih menyeluruh. Berbeda dengan analisis sebelumnya yang hanya fokus pada gen signifikan Up dan Down, GSEA mempertimbangkan seluruh gen yang telah diranking berdasarkan besar perubahan ekspresinya. Dengan cara ini, jalur biologis yang menunjukkan kecenderungan peningkatan atau penurunan secara kolektif tetap dapat terdeteksi. Dengan demikian, GSEA melengkapi analisis sebelumnya dan memberikan gambaran yang lebih komprehensif mengenai dinamika molekuler yang terjadi.

.Hasil dan Interpretasi

Sebelum dilakukan analisis ekspresi diferensial gen, dilakukan evaluasi awal terhadap kualitas dan distribusi data ekspresi gen pada dataset yang dianalisis. Tahapan ini bertujuan untuk memastikan bahwa data yang digunakan memiliki distribusi yang konsisten antar sampel serta tidak menunjukkan adanya bias teknis yang dapat mempengaruhi hasil analisis selanjutnya. Evaluasi ini penting dalam analisis bioinformatika berbasis data mikroarray atau transcriptomic karena kualitas distribusi data sangat menentukan keandalan identifikasi gen yang terekspresi secara diferensial.

1. Kualitas Data Ekspresi dan Analisis Dimensionality Reduction (UMAP)

Evaluasi distribusi data dilakukan menggunakan tiga pendekatan visualisasi, yaitu boxplot, density plot, dan Uniform Manifold Approximation and Projection (UMAP). Boxplot digunakan untuk menggambarkan distribusi statistik nilai ekspresi gen pada setiap sampel, sehingga dapat diketahui keseragaman median serta variasi ekspresi antar sampel. Density plot digunakan untuk mengevaluasi pola distribusi kepadatan nilai ekspresi gen pada masing-masing kelompok sampel sehingga dapat terlihat kesamaan atau pergeseran distribusi ekspresi gen antar kelompok. Sementara itu, analisis UMAP digunakan untuk melakukan reduksi dimensi terhadap data ekspresi gen yang berdimensi tinggi sehingga memungkinkan visualisasi pola pengelompokan sampel berdasarkan karakteristik ekspresi gen secara global.

Hasil boxplot pada kedua dataset menunjukkan bahwa distribusi nilai ekspresi gen setelah transformasi log2 relatif homogen di seluruh sampel. Hal ini terlihat dari posisi median yang berada pada kisaran nilai yang hampir sama serta rentang interkuartil (IQR) yang relatif konsisten antar sampel. Pada dataset GSE65194, sampel yang terdiri dari subtipe HER2, Luminal A, Luminal B, TNBC, dan jaringan normal menunjukkan pola distribusi yang serupa tanpa adanya penyimpangan distribusi yang mencolok. Pola yang sama juga terlihat pada dataset GSE45827 yang mencakup subtipe Basal, HER2, Luminal A, Luminal B, serta jaringan normal, di mana median dan sebaran nilai ekspresi antar sampel tetap relatif konsisten **(Gambar 1).** Meskipun terdapat variasi kecil pada beberapa sampel, perbedaan tersebut masih berada dalam rentang yang wajar dan tidak menunjukkan adanya outlier global yang signifikan. Secara keseluruhan, keseragaman distribusi nilai ekspresi gen pada kedua dataset menunjukkan bahwa proses normalisasi data telah berjalan dengan baik sehingga variasi teknis antar sampel dapat diminimalkan, dan data dinilai memiliki kualitas yang memadai untuk digunakan pada analisis lanjutan seperti identifikasi gen diferensial dan analisis bioinformatika berikutnya.

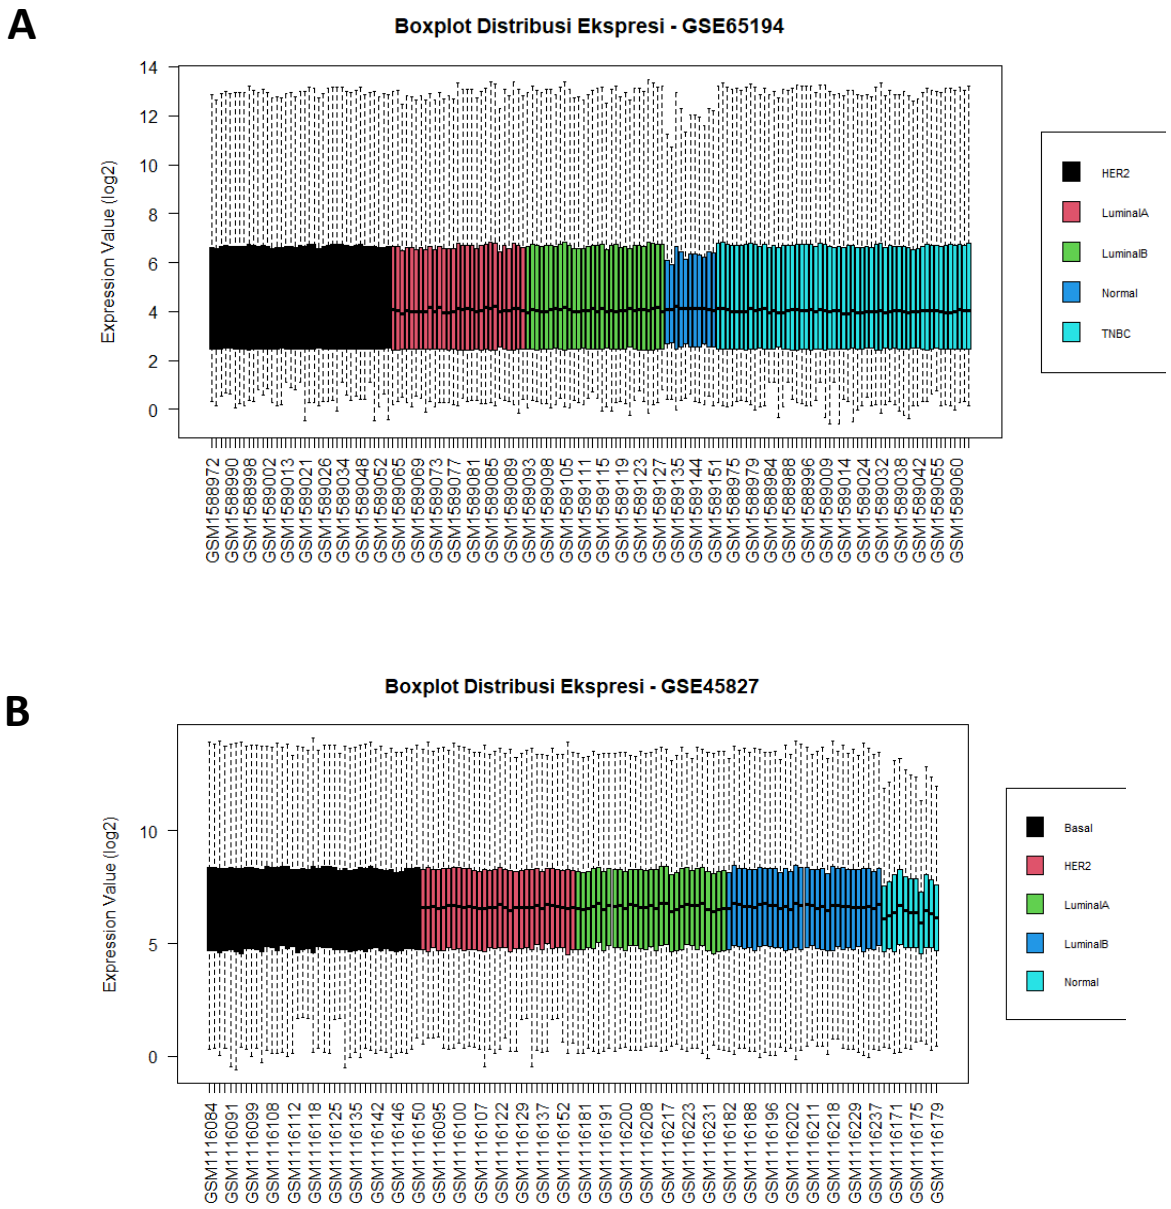

Gambar 1. A. Boxplot distribusi ekspresi dataset GSE65194. B. Boxplot distribusi ekspresi dataset GSE45827

Berdasarkan analisis distribusi nilai ekspresi gen dan visualisasi UMAP pada dataset GSE65194 dan GSE45827, terlihat bahwa distribusi ekspresi gen antar kelompok sampel memiliki pola yang relatif serupa setelah transformasi log2, yang ditunjukkan oleh kurva density yang saling tumpang tindih dengan puncak distribusi pada kisaran nilai yang hampir sama. Hal ini mengindikasikan bahwa proses normalisasi data telah berhasil mengurangi variasi teknis sehingga distribusi ekspresi gen antar sampel menjadi lebih konsisten dan dapat dibandingkan secara langsung **(Gambar 2).** Meskipun demikian, pada visualisasi UMAP terlihat pemisahan yang cukup jelas antar subtipe kanker payudara, menunjukkan bahwa profil ekspresi gen tetap mampu membedakan karakteristik biologis masing-masing kelompok. Pada dataset GSE65194, kelompok Normal dan TNBC membentuk klaster yang terpisah cukup jelas dari subtipe lainnya, sementara HER2, LuminalA, dan LuminalB berada pada area yang relatif berdekatan namun masih menunjukkan kecenderungan pengelompokan tersendiri. Pola yang serupa juga terlihat pada dataset GSE45827, di mana kelompok Basal, HER2, LuminalA, dan LuminalB membentuk klaster yang berbeda, sedangkan sampel Normal terpisah cukup jauh dari kelompok kanker**(Gambar 3)**. Secara keseluruhan, hasil ini menunjukkan bahwa meskipun distribusi global ekspresi gen antar sampel relatif seragam, pola ekspresi gen spesifik tetap mampu membedakan subtipe kanker payudara secara jelas pada analisis dimensi rendah menggunakan UMAP.

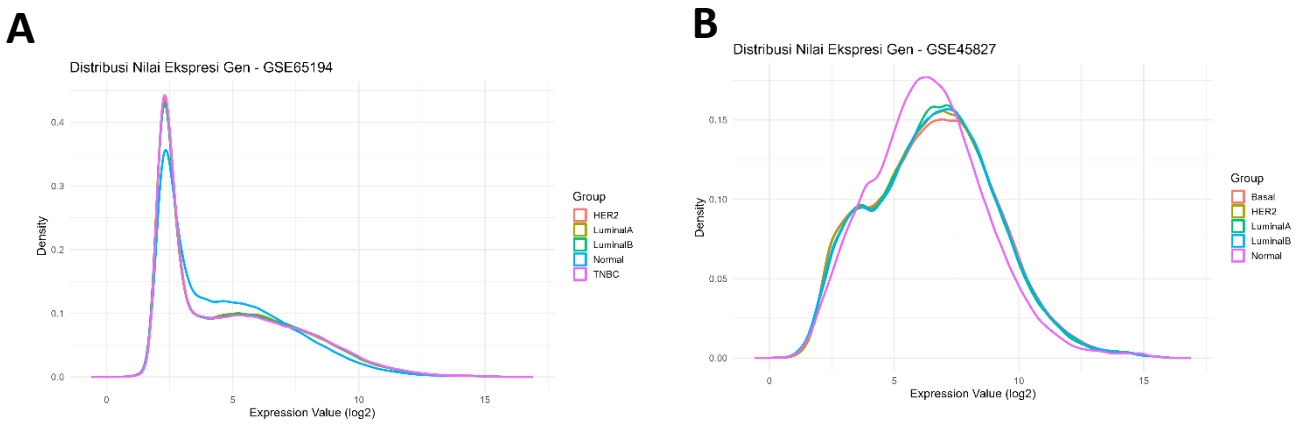

Gambar 2. A. Density plot dataset GSE65194. B. Density plot ekspresi dataset GSE45827

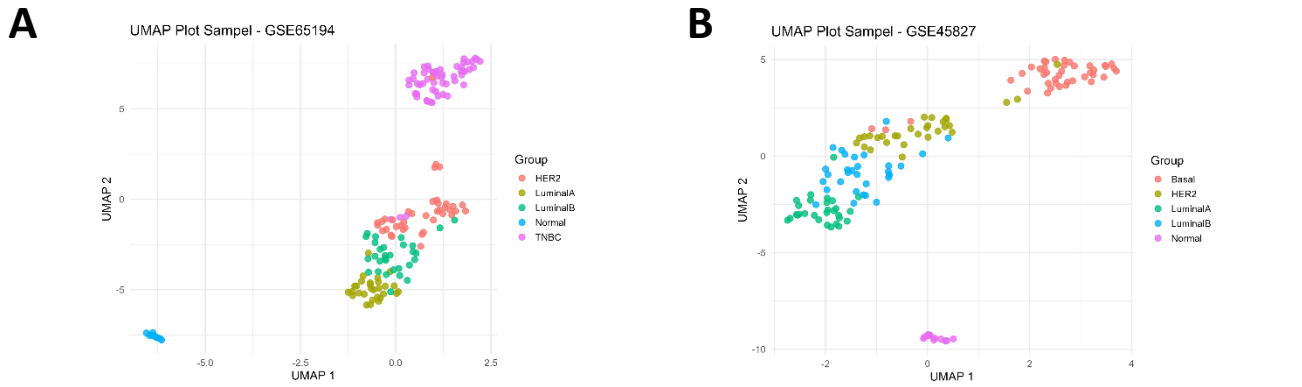

Gambar 3. A. UMAP dataset GSE65194. B. UMAP plot ekspresi dataset GSE45827

2. Gen Ekspresi Diferensial (Volcano Plot)

Analisis ekspresi gen diferensial dilakukan pada dua dataset mikroarray, yaitu GSE65194 dan GSE45827, untuk mengidentifikasi gen yang mengalami peningkatan ekspresi (upregulated) maupun penurunan ekspresi (downregulated) pada masing-masing subtipe kanker payudara. Data divisualisasikan berupa volcano plot. Pada dataset GSE65194, jumlah gen yang mengalami diferensial ekspresi bervariasi antar subtipe. Subtipe TNBC menunjukkan jumlah DEG tertinggi yaitu sebanyak 3881 gen yang terdiri dari 2635 gen upregulated dan 1246 gen downregulated. Subtipe HER2 memiliki 3579 DEG dengan 2419 gen upregulated dan 1160 gen downregulated, diikuti oleh Luminal B dengan 3368 DEG yang terdiri dari 2350 gen upregulated dan 1018 gen downregulated. Sementara itu, Luminal A menunjukkan jumlah DEG paling rendah yaitu sebanyak 2833 gen dengan 2007 gen upregulated dan 826 gen downregulated **(Gambar 4)**

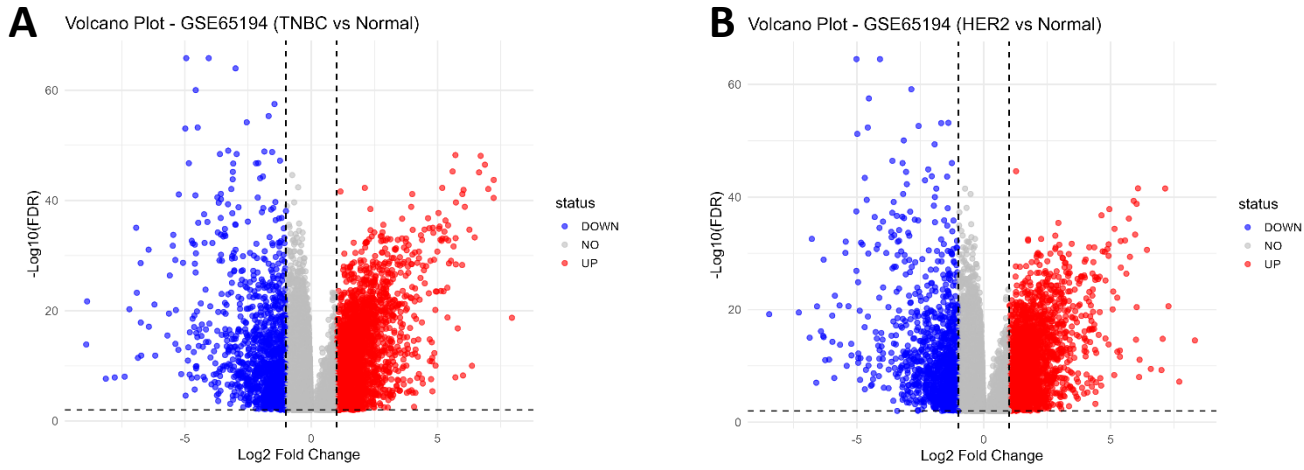

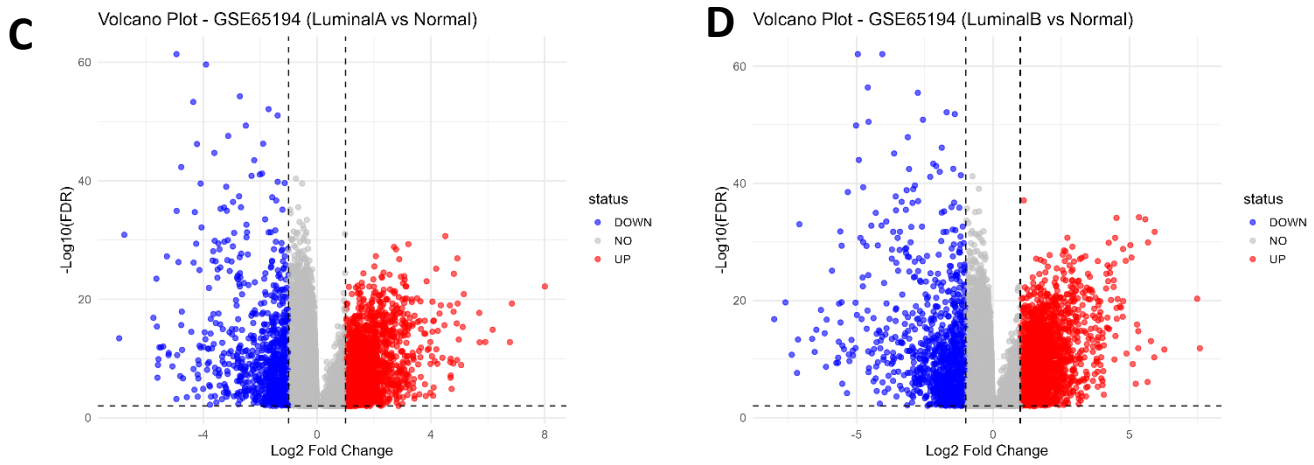

Gambar 4. Volcano plot dataset GSE61954 A. TNBC vs Normal, B. HER vs Normal, C. Luminal A vs Normal, D. Luminal B vs Normal

Pola yang serupa juga terlihat pada dataset GSE45827. Subtipe Basal memiliki jumlah DEG tertinggi yaitu 4643 gen yang terdiri dari 3127 gen upregulated dan 1516 gen downregulated. Subtipe HER2 memiliki 4342 DEG dengan 2910 gen upregulated dan 1432 gen downregulated, diikuti oleh Luminal B dengan 4097 DEG yang terdiri dari 2868 gen upregulated dan 1229 gen downregulated. Luminal A kembali menunjukkan jumlah DEG paling rendah yaitu 3491 gen dengan 2492 gen upregulated dan 999 gen downregulated. Secara umum, pada kedua dataset terlihat bahwa jumlah gen yang mengalami peningkatan ekspresi lebih besar dibandingkan gen yang mengalami penurunan ekspresi pada semua subtipe, dan subtipe TNBC/Basal menunjukkan jumlah DEG paling tinggi dibandingkan subtipe lainnya **(Gambar 5)**

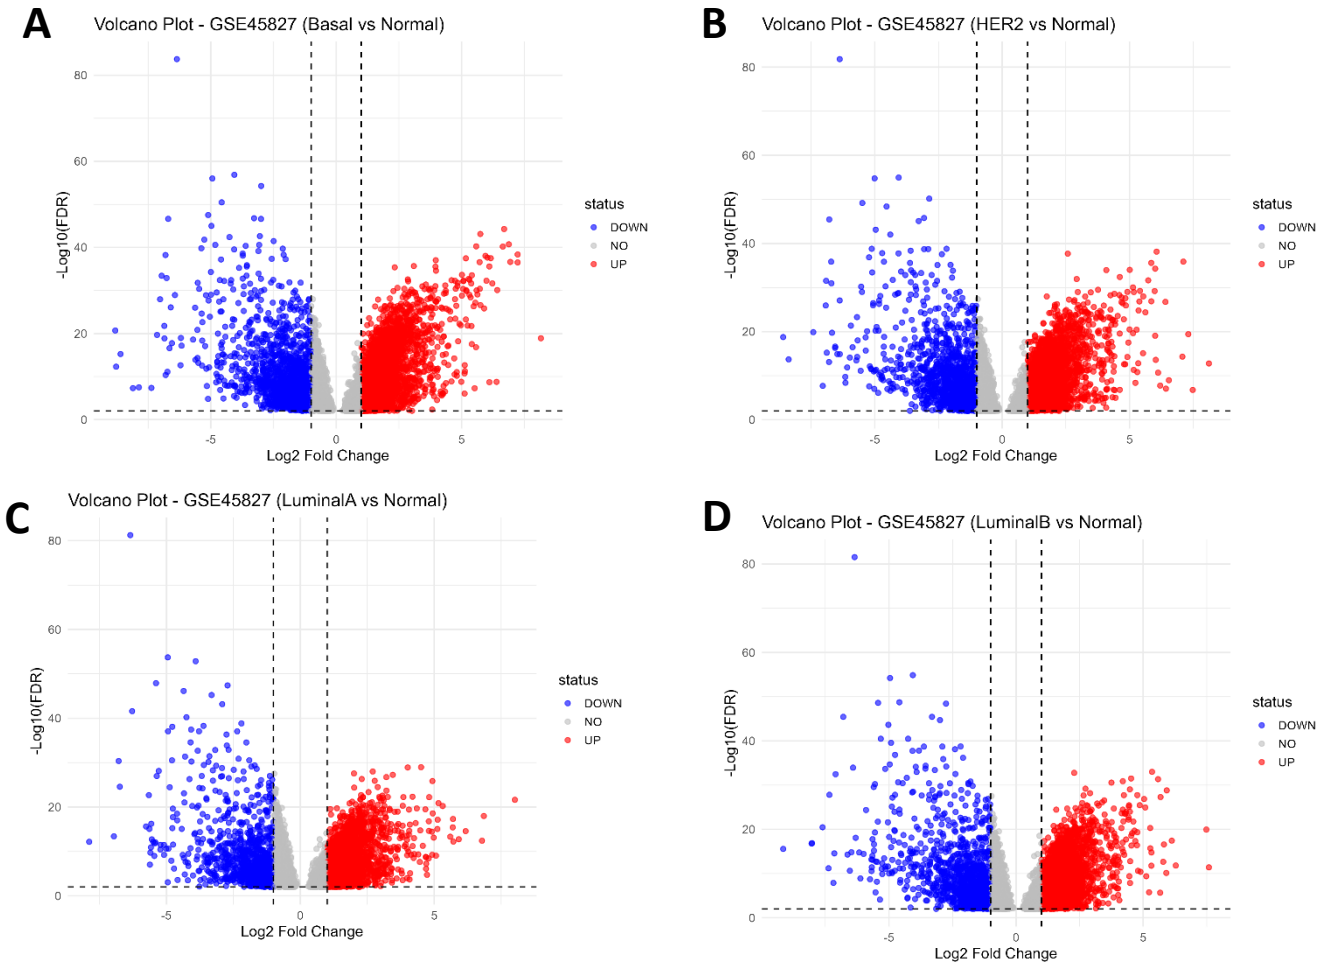

Gambar 5. Volcano plot dataset GSE45827 A. TNBC vs Normal, B. HER vs Normal, C. Luminal A vs Normal, D. Luminal B vs Normal

3. Analisis Venn Diagram

Analisis diagram Venn dilakukan untuk mengidentifikasi gen spesifik subtipe serta gen yang sama pada seluruh subtipe dalam masing-masing dataset. Pada dataset GSE65194, analisis terhadap seluruh DEG menunjukkan bahwa terdapat 1677 gen yang diekspresikan secara umum pada semua subtipe. Selain itu, ditemukan gen spesifik pada masing-masing subtipe, dengan jumlah terbanyak pada TNBC yaitu 881 gen, diikuti oleh Luminal A sebanyak 332 gen, HER2 sebanyak 260 gen, dan Luminal B sebanyak 207 gen. Pada analisis gen upregulated, ditemukan 1122 gen yang sama pada seluruh subtipe, sedangkan gen spesifik terbanyak kembali ditemukan pada TNBC yaitu 641 gen. Pada gen downregulated, terdapat 550 gen yang sama pada semua subtipe, dengan jumlah gen spesifik terbesar juga terdapat pada TNBC yaitu 293 gen. Temuan ini menunjukkan bahwa meskipun terdapat sejumlah gen yang umum pada seluruh subtipe, subtipe TNBC memiliki karakteristik ekspresi gen yang lebih spesifik dibandingkan subtipe lainnya **(Gambar 6 A-C)**

Hasil yang relatif serupa juga ditemukan pada dataset GSE45827. Pada analisis seluruh DEG, terdapat 2083 gen yang sama pada semua subtipe. Selain itu, subtipe Basal memiliki jumlah gen spesifik paling tinggi yaitu 994 gen, diikuti oleh Luminal A sebanyak 413 gen, HER2 sebanyak 284 gen, dan Luminal B sebanyak 240 gen. Pada gen upregulated, ditemukan 1412 gen yang sama pada seluruh subtipe, dengan gen spesifik terbanyak kembali terdapat pada subtipe Basal yaitu 708 gen. Pada analisis gen downregulated, terdapat 664 gen yang sama pada semua subtipe, sementara jumlah gen spesifik terbanyak juga ditemukan pada subtipe Basal yaitu 348 gen. Hasil ini menunjukkan bahwa subtipe basal atau TNBC memiliki profil ekspresi gen yang lebih khas dibandingkan subtipe lain **(Gambar 6 D-F)**

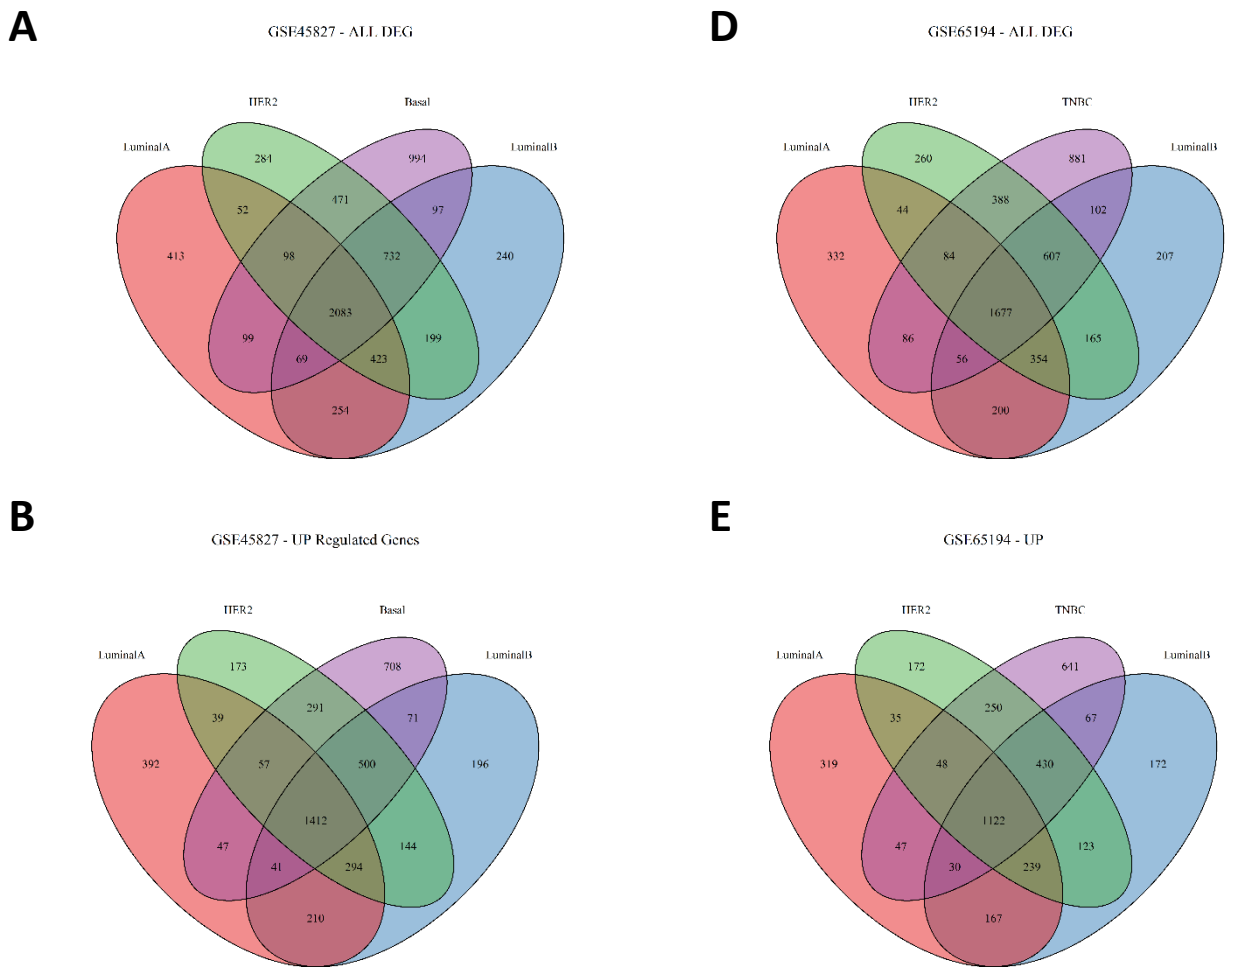

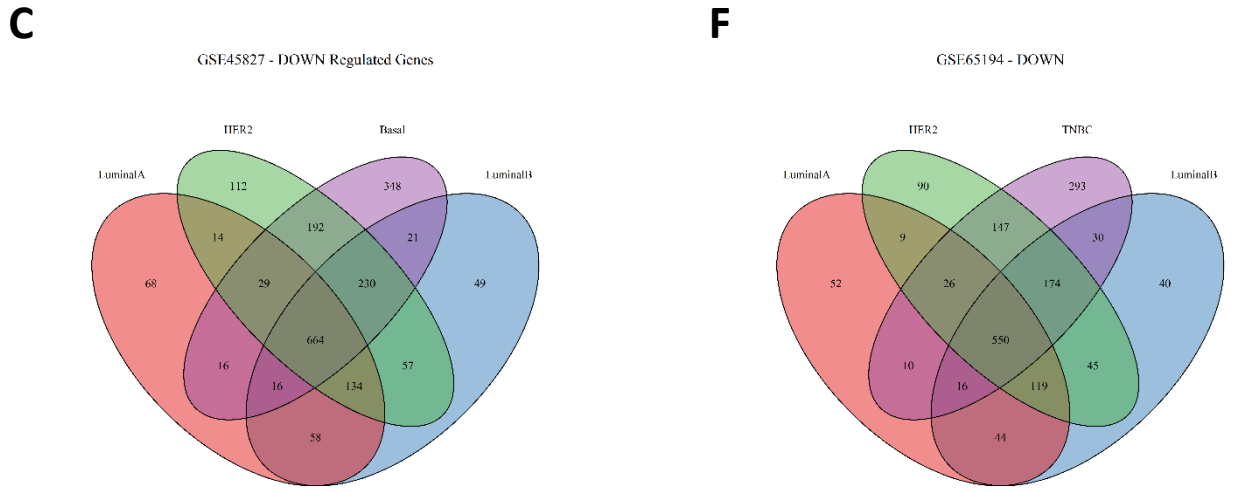

Gambar 6. Analisis Venn terhadap 4 subtipe kanker pada masing masing dataset. A. DEGs All, B. DEGs UP, C. DEGs Down pada dataset GSE61954. D. DEGs All, E. DEGs UP, F. DEGs Down pada dataset GSE4587

Untuk meningkatkan reliabilitas hasil, dilakukan analisis overlap gen antara dataset GSE65194 dan GSE45827 pada masing-masing subtipe. Hasil analisis menunjukkan bahwa terdapat jumlah gen yang cukup besar yang konsisten muncul pada kedua dataset. Pada analisis seluruh DEG, overlap terbesar ditemukan pada subtipe TNBC yaitu sebanyak 3717 gen, diikuti oleh HER2 sebanyak 3421 gen, Luminal B sebanyak 3278 gen, dan Luminal A sebanyak 2739 gen. Pada gen upregulated, jumlah overlap yang ditemukan adalah 2576 gen pada TNBC, 2364 gen pada HER2, 2344 gen pada Luminal B, dan 1993 gen pada Luminal A. Sementara itu, pada gen downregulated ditemukan 1141 gen overlap pada TNBC, 1057 gen pada HER2, 934 gen pada Luminal B, dan 746 gen pada Luminal A. Hasil ini menunjukkan bahwa sebagian besar gen yang teridentifikasi sebagai DEG pada satu dataset juga ditemukan pada dataset lainnya, sehingga memperkuat konsistensi dan validitas hasil analisis ekspresi gen yang diperoleh. Selain itu, jumlah overlap yang lebih tinggi pada subtipe TNBC menunjukkan bahwa perubahan ekspresi gen pada subtipe ini lebih konsisten antar dataset dibandingkan subtipe lainnya.

4. Analisis Fungsi Biologis (GO dan KEGG)

Setelah didapatkan gen yang oerlap pada kedua dataset dilakukan analisis lanjutan yaitu Analisis Gene Ontology (GO) dan Kyoto Encyclopedia of Genes and Genomes (KEGG) dilakukan untuk mengidentifikasi fungsi biologis serta jalur molekuler yang terkait dengan gen yang mengalami perubahan ekspresi pada masing-masing subtipe kanker payudara. Gen yang teridentifikasi sebagai differentially expressed genes (DEGs) dipisahkan menjadi dua kelompok, yaitu gen yang mengalami upregulasi dan downregulasi**,** Hasil analisis difokuskan pada 20 proses biologis dan jalur teratas (top 20) berdasarkan nilai signifikansi statistik (*adjusted p-value*), sehingga dapat menggambarkan mekanisme molekuler utama yang terlibat dalam perkembangan tumor. Melalui analisis GO**,** diperoleh informasi mengenai proses biologis yang dominan dipengaruhi oleh perubahan ekspresi gen, sedangkan analisis KEGG memberikan gambaran mengenai jalur sinyal dan interaksi molekuler yang berperan dalam patogenesis kanker.

Gene Ontology (GO)

Hasil Gene Ontology (GO) Biological Process top 20 pada gen yang mengalami upregulasi menunjukkan bahwa setiap subtipe kanker payudara memiliki pola aktivitas biologis yang berbeda, meskipun beberapa proses utama saling tumpang tindih. Pada subtipe Triple-Negative Breast Cancer (TNBC), sebagian besar proses yang diperkaya berkaitan dengan pembelahan sel dan stabilitas genom, seperti chromosome segregation, nuclear division, DNA replication, dan mitotic sister chromatid segregation. Nilai p.adjust yang sangat kecil (hingga ~10^{-33}) serta jumlah gen yang besar menunjukkan bahwa jalur siklus sel dan mitosis sangat aktif, mencerminkan karakter TNBC yang memiliki proliferasi tinggi dan instabilitas kromosom. Hal ini konsisten dengan sifat TNBC yang lebih agresif dan memiliki laju pertumbuhan sel yang cepat. Sementara itu, pada subtipe HER2-Positive Breast Cancer, proses biologis yang diperkaya juga sangat berkaitan dengan mitosis dan organisasi kromosom, seperti chromosome segregation, mitotic nuclear division, spindle organization, dan microtubule cytoskeleton organization involved in mitosis.

Aktivasi proses-proses ini menunjukkan adanya peningkatan aktivitas pembelahan sel yang kuat, yang kemungkinan berkaitan dengan amplifikasi gen HER2 yang diketahui mendorong proliferasi sel tumor secara agresif melalui jalur pertumbuhan sel **(Gambar 7 A-B)**

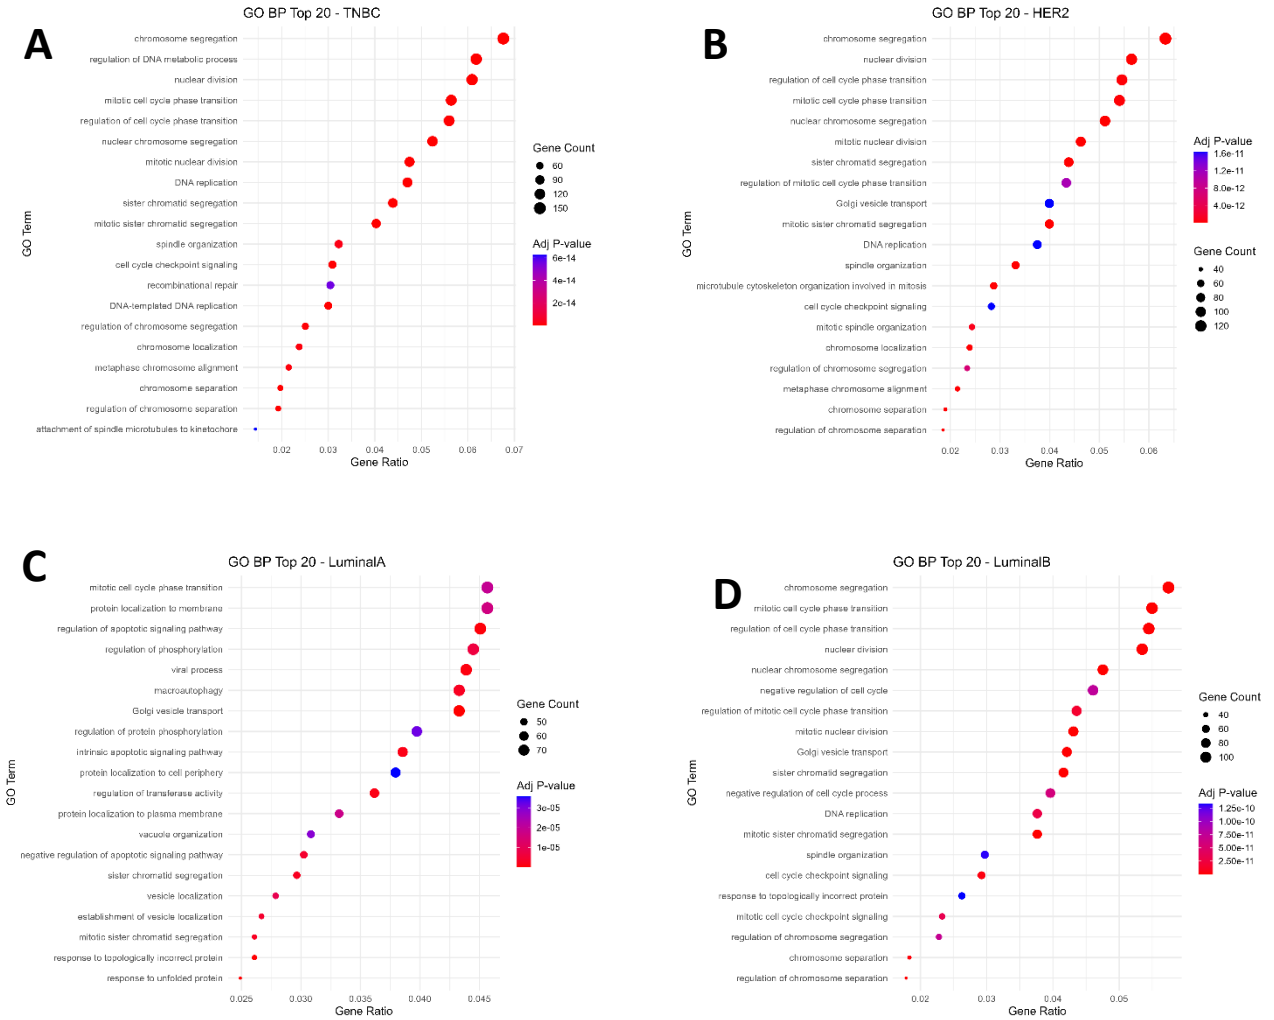

Gambar 7. Analisis Gene Ontology Biology Process pada 20 gen yang upregulasi pada setiap subtipe kanker di kedua dataset. A. TNBC, B. HER2, C. Luminal A, D. Luminal B

Pada subtipe Luminal A Breast Cancer, proses biologis yang diperkaya lebih beragam dan tidak hanya terkait proliferasi, tetapi juga regulasi apoptosis, transport vesikel, dan homeostasis protein, seperti regulation of apoptotic signaling pathway, Golgi vesicle transport, macroautophagy, serta response to unfolded protein. Hal ini menunjukkan bahwa selain mekanisme pertumbuhan sel, sel tumor pada Luminal A juga melibatkan mekanisme adaptasi stres seluler dan regulasi kematian sel, yang sejalan dengan karakter subtipe ini yang umumnya memiliki proliferasi lebih rendah dan prognosis lebih baik dibanding subtipe agresif lainnya. Pada subtipe Luminal B Breast Cancer, pola proses biologis kembali didominasi oleh regulasi siklus sel dan pembelahan mitosis, seperti chromosome segregation, mitotic cell cycle phase transition, DNA replication, dan cell cycle checkpoint signaling. Banyaknya gen yang terlibat menunjukkan bahwa subtipe ini memiliki aktivitas proliferatif yang tinggi, lebih kuat dibanding Luminal A. Hal ini sesuai dengan karakter biologis Luminal B yang memiliki tingkat proliferasi lebih tinggi dan prognosis lebih buruk dibanding Luminal A, meskipun masih termasuk kelompok tumor dengan ekspresi reseptor hormone **(Gambar 7 C-D)**

Hasil analisis Gene Ontology (GO) Biological Process pada gen yang mengalami downregulasi menunjukkan bahwa beberapa proses biologis penting mengalami penurunan aktivitas pada berbagai subtipe kanker payudara. Pada subtipe Triple-Negative Breast Cancer (TNBC), proses biologis yang mengalami penurunan terutama berkaitan dengan metabolisme lipid, organisasi matriks ekstraseluler, serta regulasi angiogenesis, seperti regulation of lipid metabolic process, fatty acid metabolic process, extracellular matrix organization, dan regulation of angiogenesis. Proses lain seperti cell-substrate adhesion dan cell-matrix adhesion juga menunjukkan penurunan ekspresi gen. Hal ini menunjukkan bahwa fungsi normal yang mengatur interaksi sel dengan matriks ekstraseluler dan keseimbangan metabolisme lipid mengalami penekanan pada sel tumor. Pada subtipe HER2-

Positive Breast Cancer, gen yang mengalami downregulasi terutama berkaitan dengan organisasi matriks ekstraseluler, metabolisme lipid, dan regulasi angiogenesis, seperti extracellular matrix organization, fatty acid metabolic process, regulation of angiogenesis, dan regulation of endothelial cell proliferation. Selain itu, proses seperti cell-matrix adhesion dan ameboidal-type cell migration juga menunjukkan penurunan aktivitas gen. Penurunan ekspresi gen dalam proses-proses tersebut menunjukkan adanya penekanan terhadap mekanisme fisiologis yang mengatur struktur jaringan dan interaksi sel dengan lingkungan mikro. **(Gambar 8 A-B)**

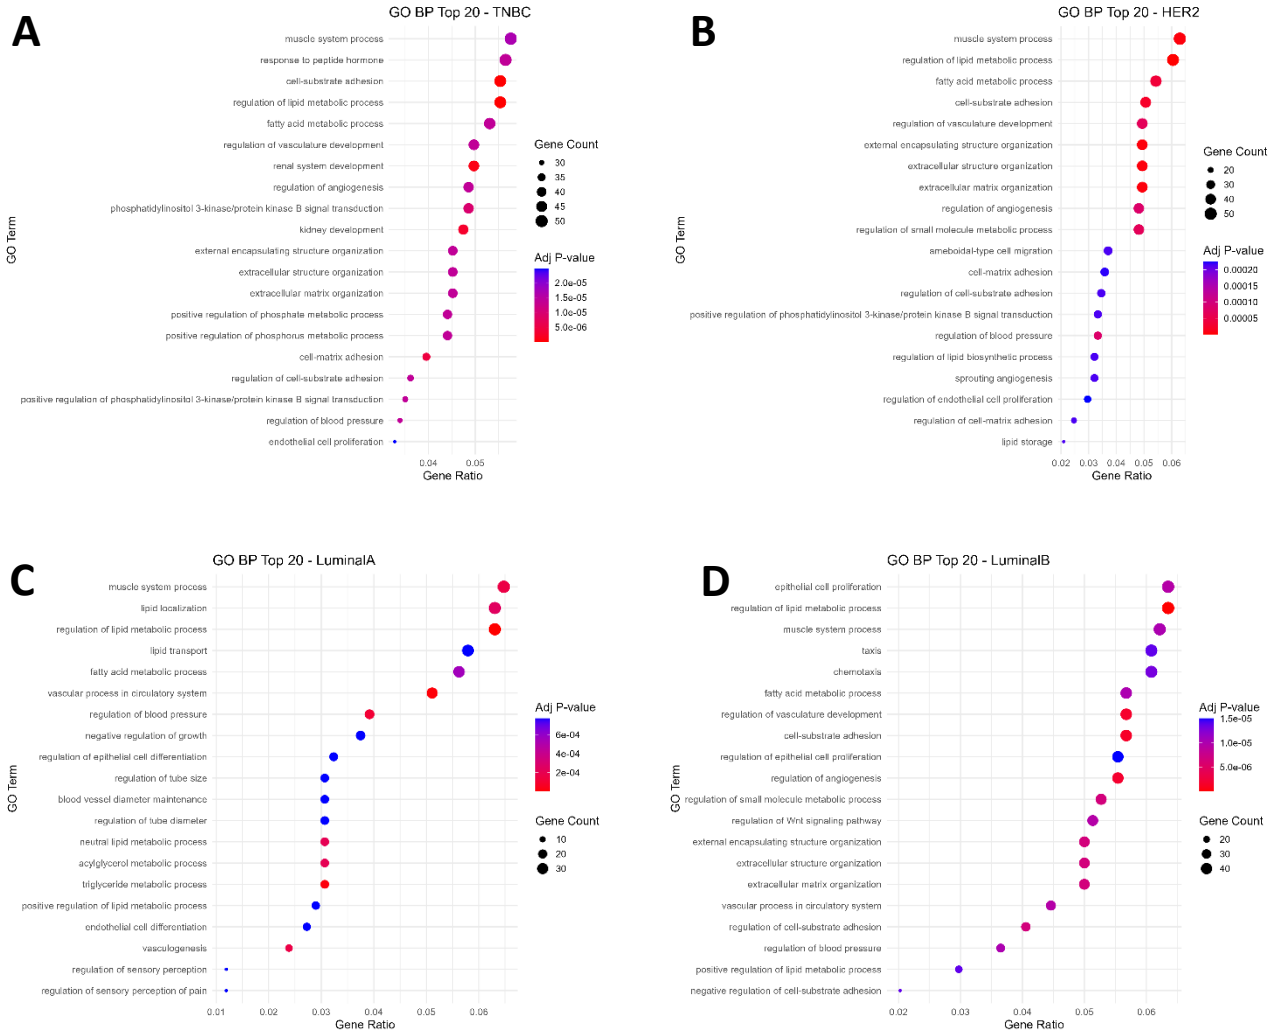

Gambar 8. Analisis Gene Ontology Biology Process pada 20 gen yang downregulasi pada setiap subtipe kanker di kedua dataset. A. TNBC, B. HER2, C. Luminal A, D. Luminal B

Pada subtipe Luminal A Breast Cancer, gen yang mengalami downregulasi terutama terlibat dalam metabolisme lipid dan proses vaskular, termasuk lipid transport, triglyceride metabolic process, acylglycerol metabolic process, serta vascular process in circulatory system. Selain itu, proses seperti negative regulation of growth dan regulation of epithelial cell differentiation juga mengalami penurunan. Penurunan ekspresi gen dalam proses-proses ini menunjukkan bahwa mekanisme fisiologis yang biasanya berperan dalam mengontrol pertumbuhan sel dan metabolisme lipid menjadi kurang aktif pada sel tumor. Pada subtipe Luminal B Breast Cancer, proses biologis yang mengalami penurunan mencakup regulasi metabolisme lipid, migrasi sel, dan organisasi matriks ekstraseluler, seperti regulation of lipid metabolic process, chemotaxis, cell-substrate adhesion, dan extracellular matrix organization. Selain itu, proses seperti regulation of Wnt signaling pathway dan regulation of epithelial cell proliferation juga muncul dalam daftar. Penurunan ekspresi gen pada proses-proses ini dapat mencerminkan berkurangnya aktivitas jalur yang secara normal mengatur komunikasi sel, diferensiasi, dan struktur jaringan, yang berpotensi memengaruhi perilaku biologis sel tumor **(Gambar 8 C-D)**

Kyoto Encyclopedia of Genes and Genomes (KEGG)

Hasil analisis Kyoto Encyclopedia of Genes and Genomes (KEGG) pada gen yang mengalami upregulasi menunjukkan adanya aktivasi beberapa jalur molekuler yang berhubungan dengan proliferasi sel, regulasi siklus sel, serta proses imun dan infeksi yang sering terkait dengan mekanisme perkembangan kanker. Pada subtipe Triple-Negative Breast Cancer (TNBC), jalur yang paling signifikan adalah Cell cycle dan DNA replication, yang memiliki nilai signifikansi sangat tinggi. Hal ini menunjukkan bahwa gen yang mengalami peningkatan ekspresi terutama berperan dalam proliferasi dan pembelahan sel yang aktif, yang merupakan karakteristik utama tumor TNBC yang dikenal memiliki laju pertumbuhan tinggi. Selain itu, jalur seperti Cellular senescence, TNF signaling pathway, serta NOD-like receptor signaling pathway juga muncul dalam hasil analisis, menunjukkan keterlibatan regulasi respons inflamasi dan mekanisme stres seluler dalam perkembangan tumor pada subtipe ini. Sementara itu, pada subtipe HER2-Positive Breast Cancer, jalur yang diperkaya meliputi Cell cycle, Protein processing in endoplasmic reticulum, Apoptosis, serta DNA replication. Jalur-jalur ini menunjukkan bahwa gen yang mengalami upregulasi berperan dalam regulasi proliferasi sel dan kontrol kualitas protein, yang penting dalam mempertahankan aktivitas sel tumor. Selain itu, munculnya jalur seperti Toll-like receptor signaling pathway dan NOD-like receptor signaling pathway juga menunjukkan keterlibatan jalur respons imun dan inflamasi, yang diketahui berkontribusi terhadap interaksi antara sel tumor dan lingkungan mikro tumor **(Gambar 9 A-B)**

Pada subtipe Luminal A Breast Cancer, jalur yang diperkaya meliputi Lysosome, Endocytosis, Protein processing in endoplasmic reticulum, serta Cell cycle. Jalur-jalur ini menunjukkan bahwa gen yang mengalami upregulasi berperan dalam proses degradasi protein, transport vesikel, dan regulasi siklus sel, yang penting dalam mempertahankan homeostasis sel tumor. Selain itu, munculnya jalur seperti FoxO signaling pathway dan Sphingolipid signaling pathway juga menunjukkan keterlibatan mekanisme regulasi pertumbuhan sel dan apoptosis, yang sering dikaitkan dengan perkembangan berbagai jenis kanker. Pada subtipe Luminal B Breast Cancer, jalur yang diperkaya mencakup Cell cycle, DNA replication, Autophagy, dan Apoptosis. Aktivasi jalur-jalur ini menunjukkan bahwa gen yang mengalami upregulasi berperan dalam regulasi proliferasi sel serta mekanisme keseimbangan antara kelangsungan hidup dan kematian sel. Selain itu, jalur metabolisme seperti Pyrimidine metabolism dan Nucleotide metabolism juga muncul dalam hasil analisis, yang mengindikasikan adanya peningkatan kebutuhan biosintesis nukleotida untuk mendukung replikasi DNA pada sel tumor yang berkembang cepat **(Gambar 9 C-D)**

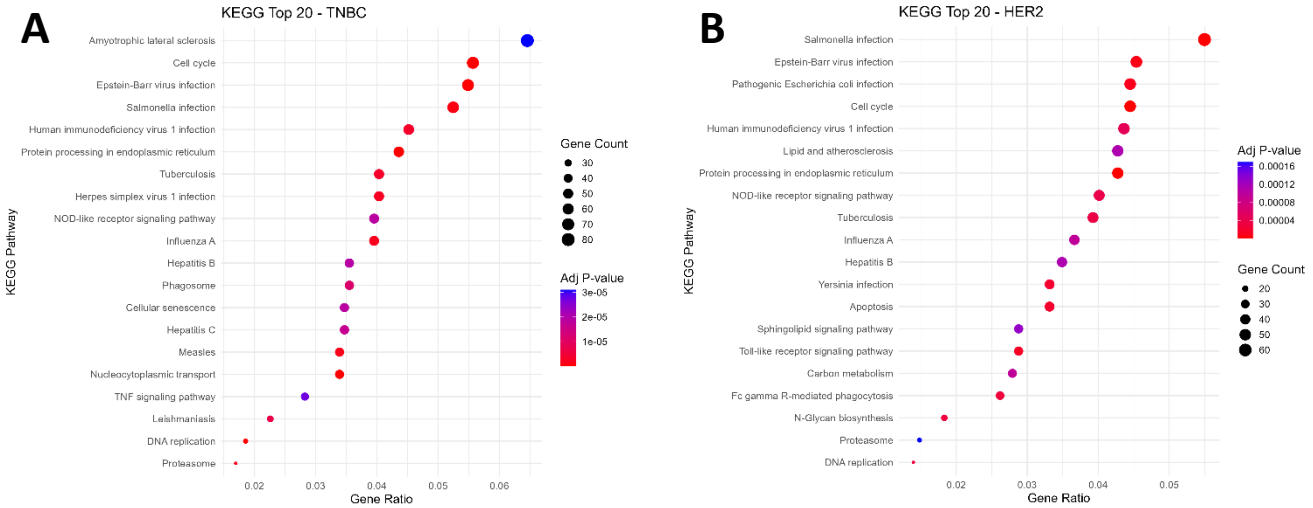

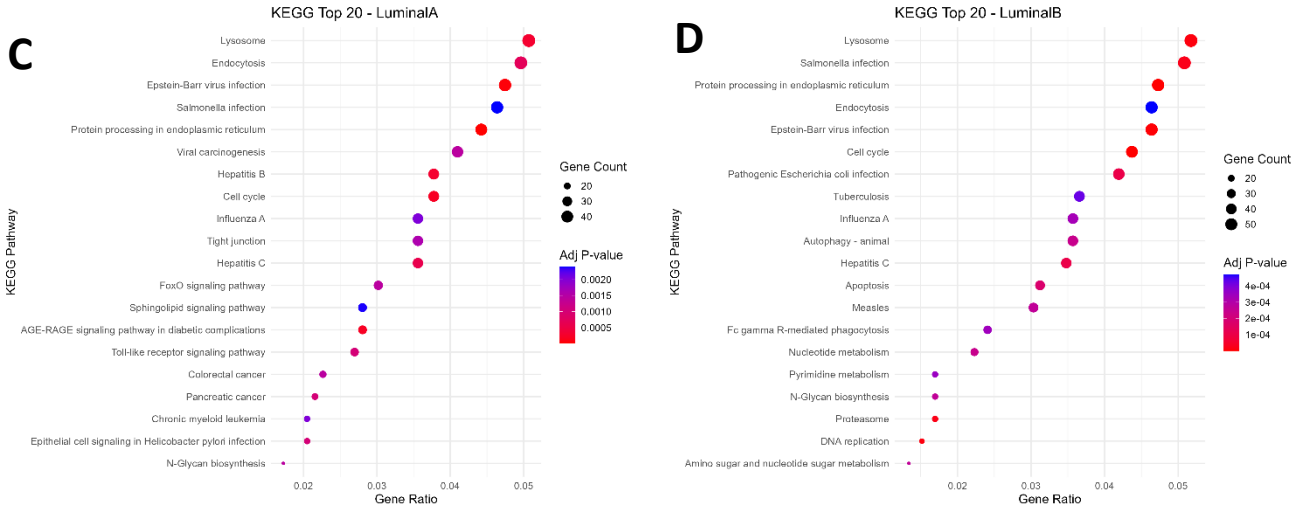

Gambar 9. Analisis KEGG pada 20 gen yang upregulasi pada setiap subtipe kanker di kedua dataset. A. TNBC, B. HER2, C. Luminal A, D. Luminal B

Hasil analisis Kyoto Encyclopedia of Genes and Genomes (KEGG) pada gen yang mengalami downregulasi mekanisme biologis yang secara normal membantu mengatur metabolisme, adhesi sel, atau kontrol pertumbuhan, namun ekspresinya menurun pada sel kanker. Pada subtipe Triple-Negative Breast Cancer (TNBC), beberapa jalur penting yang mengalami penurunan meliputi PI3K-Akt signaling pathway, Focal adhesion, Integrin signaling, dan ECM-receptor interaction. Jalur adhesi sel seperti focal adhesion dan integrin signaling berperan dalam mempertahankan interaksi normal antara sel dan matriks ekstraseluler. Penurunan ekspresi gen dalam jalur tersebut dapat mencerminkan berkurangnya kontrol terhadap adhesi dan struktur jaringan, yang berpotensi mempermudah perubahan sifat sel menjadi lebih invasif. Selain itu, penurunan jalur metabolik seperti AMPK signaling pathway, PPAR signaling pathway, dan regulation of lipolysis in adipocytes menunjukkan adanya penekanan terhadap regulasi metabolisme energi normal, yang dapat mengubah cara sel tumor memanfaatkan sumber energi untuk mendukung pertumbuhan yang tidak terkontrol. Pada subtipe HER2-Positive Breast Cancer, beberapa jalur yang mengalami penurunan ekspresi gen meliputi PI3K-Akt signaling pathway, Ras signaling pathway, integrin signaling, serta focal adhesion. Selain itu, jalur metabolisme seperti PPAR signaling pathway, pyruvate metabolism, dan fatty acid degradation juga terdeteksi dalam hasil analisis. Penurunan aktivitas gen dalam jalur-jalur ini menunjukkan adanya penekanan terhadap regulasi metabolisme energi dan interaksi sel dengan matriks ekstraseluler, yang merupakan bagian dari fungsi fisiologis normal sel **(Gambar 10 A-B).**

Pada subtipe Luminal A Breast Cancer, jalur yang mengalami penurunan sebagian besar berkaitan dengan metabolisme lipid dan energi, seperti PPAR signaling pathway, pyruvate metabolism, glycerolipid metabolism, serta glycolysis/gluconeogenesis. Penurunan ekspresi gen dalam jalur tersebut menunjukkan bahwa mekanisme metabolisme normal mengalami perubahan pada sel tumor. Selain itu, jalur seperti Ras signaling pathway, Notch signaling pathway, dan integrin signaling juga teridentifikasi, yang menunjukkan adanya penurunan ekspresi gen yang terlibat dalam regulasi diferensiasi sel dan komunikasi antar sel. Pada subtipe Luminal B Breast Cancer, jalur yang mengalami penurunan meliputi PI3K-Akt signaling pathway, Ras signaling pathway, dan AMPK signaling pathway, yang merupakan bagian dari jaringan regulasi pertumbuhan sel dan metabolisme. Selain itu, jalur adhesi sel seperti focal adhesion, integrin signaling, dan ECM-receptor interaction juga menunjukkan penurunan aktivitas gen. Penekanan terhadap jalur-jalur tersebut dapat mencerminkan perubahan dalam mekanisme kontrol struktural dan sinyal pertumbuhan normal, yang berpotensi memengaruhi perilaku biologis sel tumor **(Gambar 10 C-D).**

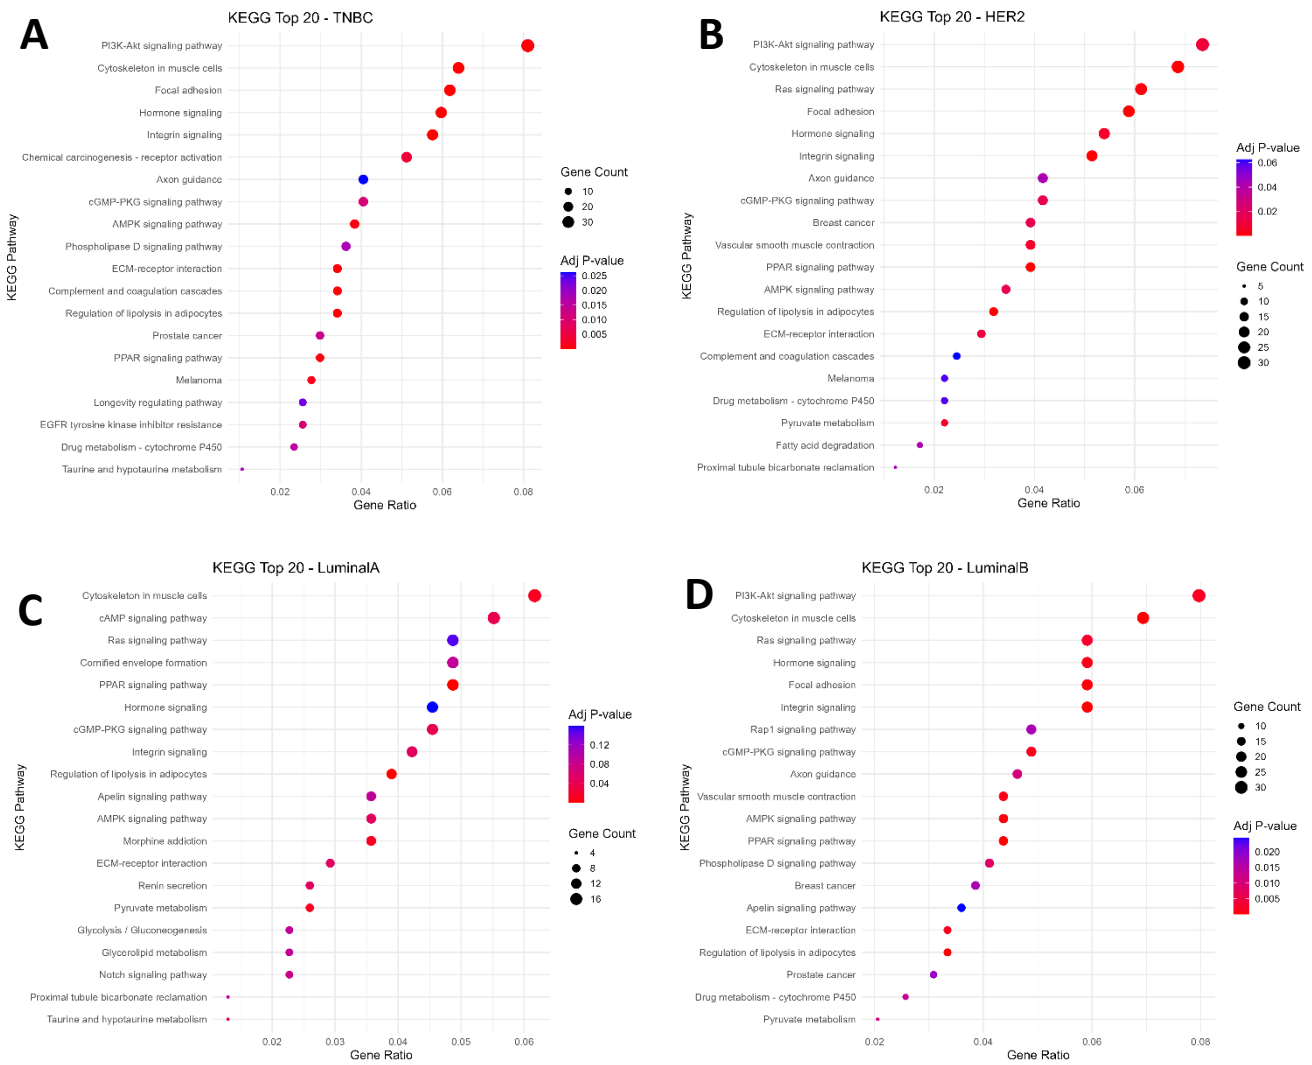

Gambar 10. Analisis KEGG pada 20 gen yang downregulasi pada setiap subtipe kanker di kedua dataset. A. TNBC, B. HER2, C. Luminal A, D. Luminal B

5. Analisis Berbasis Seluruh Gen (Gene Set Enrichment Analysis / GSEA)

Analisis Gene Set Enrichment Analysis (GSEA) dilakukan untuk mengetahui perubahan aktivitas jalur biologis (pathway) berdasarkan pola distribusi gen pada seluruh data ekspresi gen. Berbeda dengan analisis yang hanya menggunakan gen signifikan, metode GSEA mempertimbangkan seluruh gen dalam dataset sehingga dapat memberikan gambaran yang lebih menyeluruh mengenai perubahan proses biologis yang terjadi.Interpretasi utama pada analisis GSEA didasarkan pada nilai Normalized Enrichment Score (NES). Nilai NES menunjukkan arah serta kekuatan perubahan aktivitas suatu pathway pada kondisi yang dianalisis. Pathway dengan nilai NES positif (NES > 0) menunjukkan bahwa gen-gen dalam pathway tersebut cenderung memiliki ekspresi yang lebih tinggi, sehingga dapat diinterpretasikan bahwa pathway tersebut mengalami peningkatan aktivitas. Sebaliknya, nilai NES negatif (NES < 0) menunjukkan bahwa gen-gen dalam pathway tersebut cenderung memiliki ekspresi yang lebih rendah, sehingga pathway tersebut mengalami penurunan aktivitas.Besarnya nilai NES juga menggambarkan seberapa kuat perubahan aktivitas pathway tersebut. Semakin tinggi nilai absolut NES (|NES|), maka semakin kuat perubahan yang terjadi. Namun demikian, interpretasi hasil juga perlu mempertimbangkan nilai p-value dan adjusted p-value (FDR) untuk memastikan bahwa perubahan yang terdeteksi memiliki signifikansi statistik.

Hasil analisis Gene Set Enrichment Analysis (GSEA) berbasis Gene Ontology (GO) menunjukkan bahwa sebagian besar pathway yang teridentifikasi pada subtipe HER2, TNBC, dan Luminal B berkaitan dengan proses siklus sel dan pembelahan sel. Pada ketiga subtipe tersebut, pathway seperti nuclear chromosome segregation, sister chromatid segregation, chromosome segregation, mitotic nuclear division, serta cell cycle process menunjukkan nilai Normalized Enrichment Score (NES) positif, yang menandakan aktivasi pathway tersebut. Aktivasi proses-proses ini menunjukkan bahwa mekanisme yang terlibat dalam pembelahan sel, khususnya selama tahap mitosis dan pemisahan kromosom, mengalami peningkatan aktivitas. Di antara ketiganya, subtipe TNBC menunjukkan nilai NES yang relatif lebih tinggi, mengindikasikan bahwa aktivitas proliferasi sel pada subtipe ini cenderung lebih kuat dibandingkan subtipe lainnya. Berbeda dengan pola tersebut, subtipe Luminal A

menunjukkan karakteristik yang lebih beragam dengan adanya pathway yang teraktivasi maupun tertekan. Pathway yang teraktivasi pada subtipe ini terutama berkaitan dengan organisasi matriks ekstraseluler, seperti extracellular matrix organization, external encapsulating structure organization, dan collagen fibril organization, yang menunjukkan peningkatan aktivitas pada proses pengaturan struktur jaringan dan interaksi sel dengan lingkungan sekitarnya. Sebaliknya, beberapa pathway yang berkaitan dengan metabolisme lipid, termasuk fatty acid metabolic process, lipid metabolic process, dan triglyceride metabolic process, menunjukkan nilai NES negatif yang menandakan adanya penurunan aktivitas pada proses metabolisme tersebut. Pola ini menunjukkan bahwa subtipe Luminal A tidak didominasi oleh peningkatan proses proliferasi sel seperti pada subtipe lainnya, melainkan lebih mencerminkan perubahan pada aspek struktur jaringan dan regulasi metabolisme sel **(Gambar 11)**

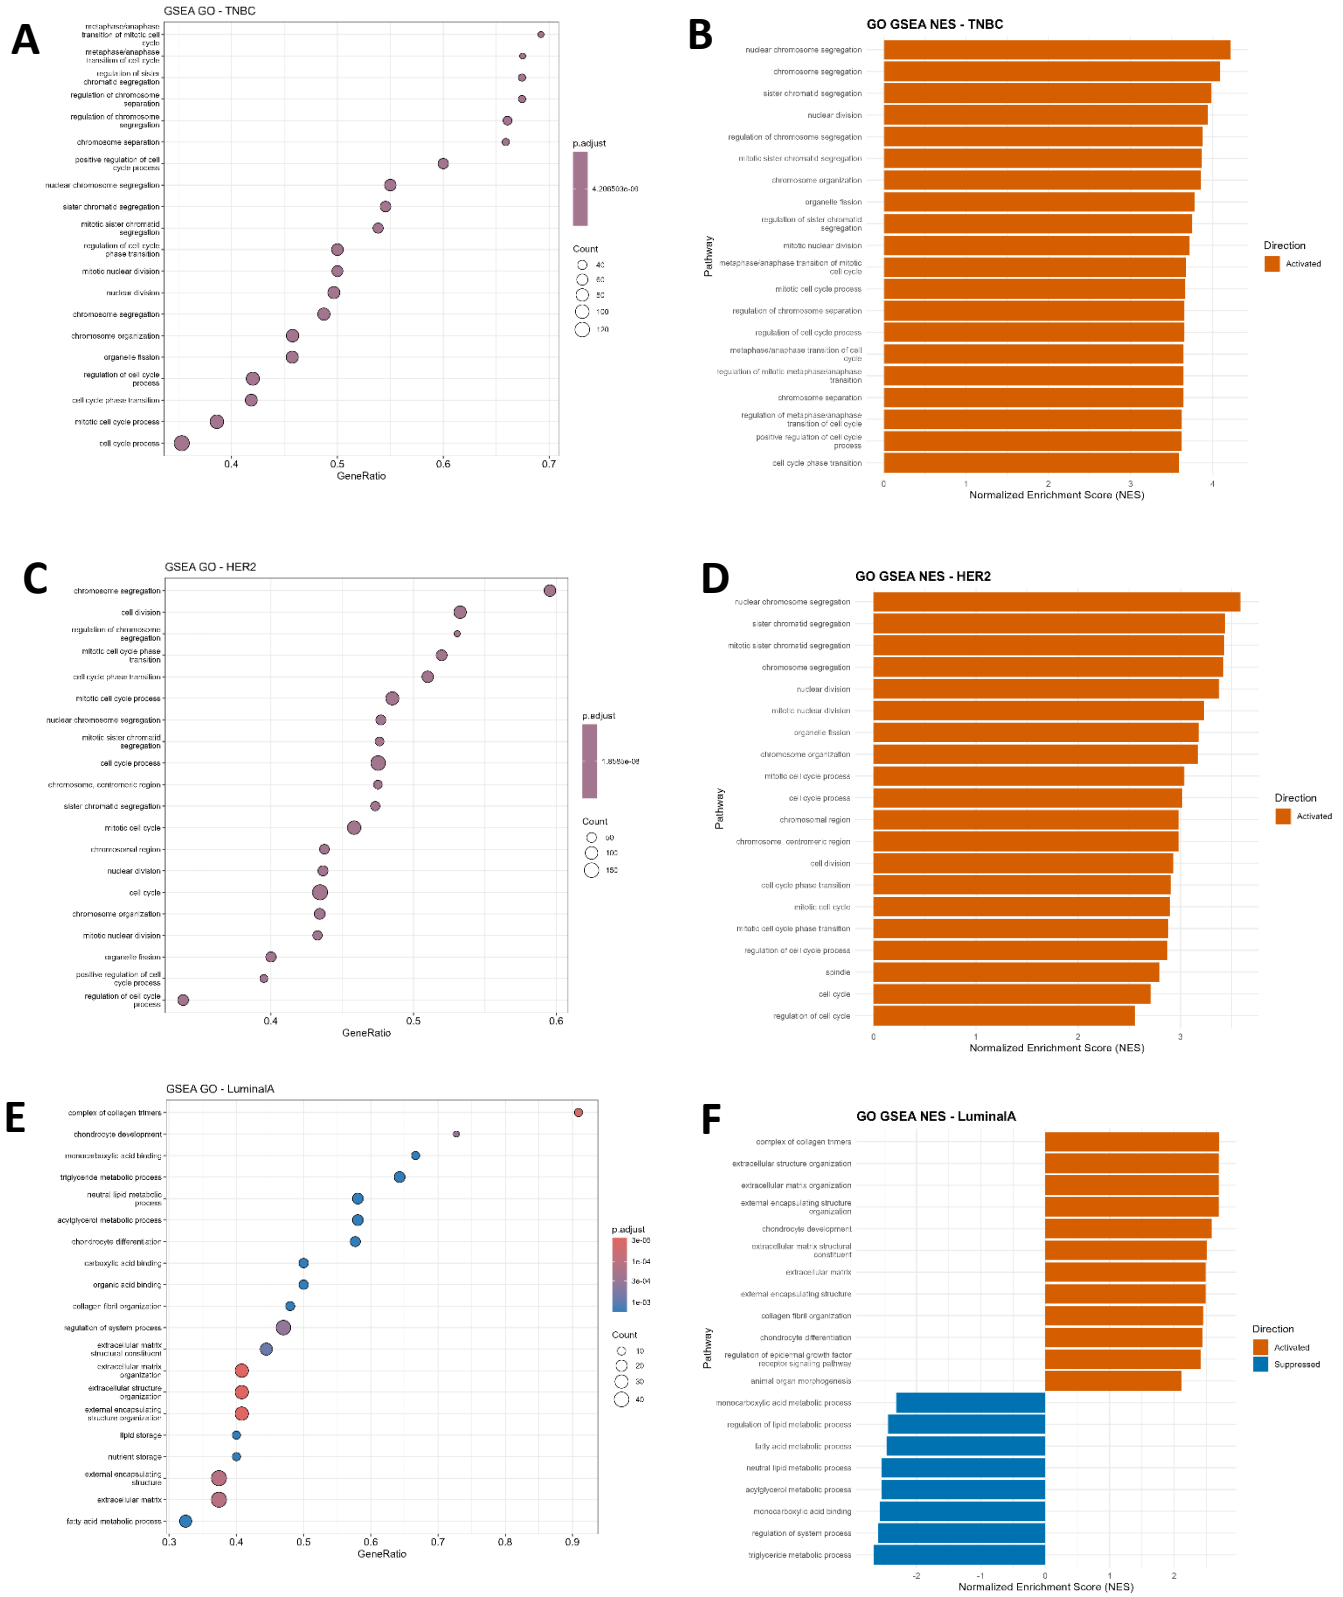

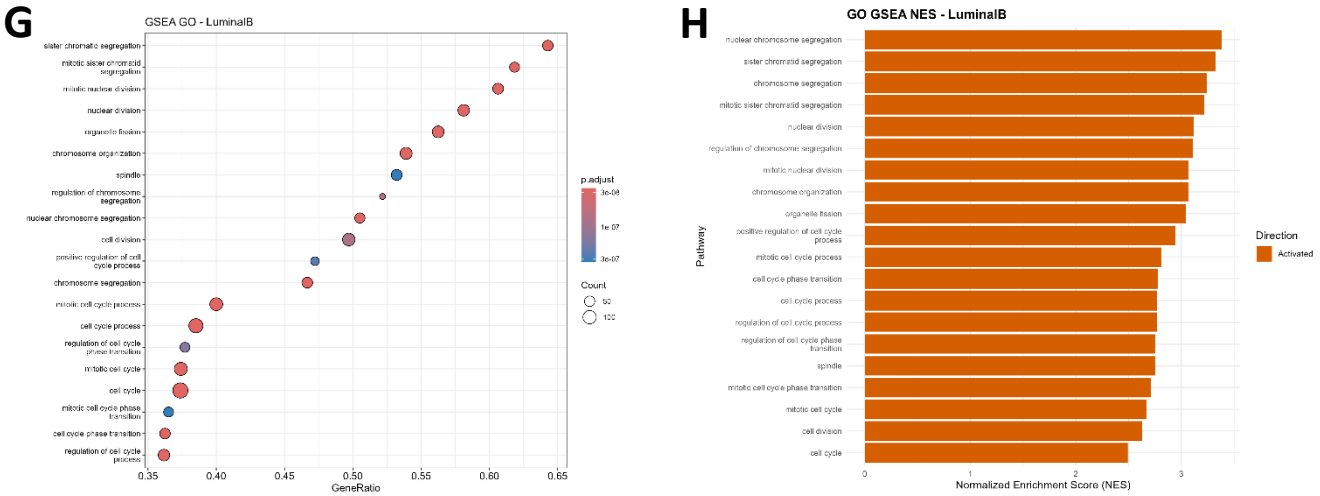

Gambar 11. Analisis GSEA GO pada masing masing subtipe kanker payudara

Hasil analisis GSEA berbasis KEGG menunjukkan adanya perbedaan pola aktivasi pathway biologis pada masing-masing subtipe kanker payudara. Pada subtipe HER2, TNBC, dan Luminal B, pathway yang mengalami aktivasi umumnya berkaitan dengan proliferasi sel dan proses replikasi DNA. Pathway seperti cell cycle, DNA replication, base excision repair, dan mismatch repair menunjukkan nilai Normalized Enrichment Score (NES) positif, yang menandakan peningkatan aktivitas pada mekanisme yang mengatur pembelahan sel serta pemeliharaan stabilitas genom. Selain itu, beberapa pathway yang berhubungan dengan respon imun dan sinyal inflamasi, seperti IL-17 signaling pathway, Toll-like receptor signaling pathway, dan NOD-like receptor signaling pathway, juga mengalami aktivasi. Pola ini menunjukkan bahwa ketiga subtipe tersebut memiliki aktivitas proliferasi sel yang tinggi serta keterlibatan jalur sinyal imun yang dapat berperan dalam perkembangan dan progresi tumor. Sebaliknya, beberapa pathway yang berkaitan dengan metabolisme lipid dan regulasi metabolik menunjukkan nilai NES negatif pada sebagian besar subtipe, termasuk PPAR signaling pathway, adipocytokine signaling pathway, drug metabolism – cytochrome P450, serta regulation of lipolysis in adipocytes. Penurunan aktivitas pathway tersebut mengindikasikan adanya perubahan regulasi metabolisme sel pada jaringan tumor. Pada subtipe Luminal A, pola yang muncul lebih didominasi oleh penekanan pathway metabolisme seperti pyruvate metabolism dan PPAR signaling pathway, sementara hanya sedikit pathway yang menunjukkan aktivasi, seperti protein digestion and absorption. Temuan ini menunjukkan bahwa subtipe Luminal A memiliki karakteristik molekuler yang lebih berkaitan dengan perubahan metabolisme dibandingkan peningkatan aktivitas proliferasi sel yang kuat seperti yang terlihat pada subtipe TNBC, HER2, dan Luminal B **(Gambar 12)**

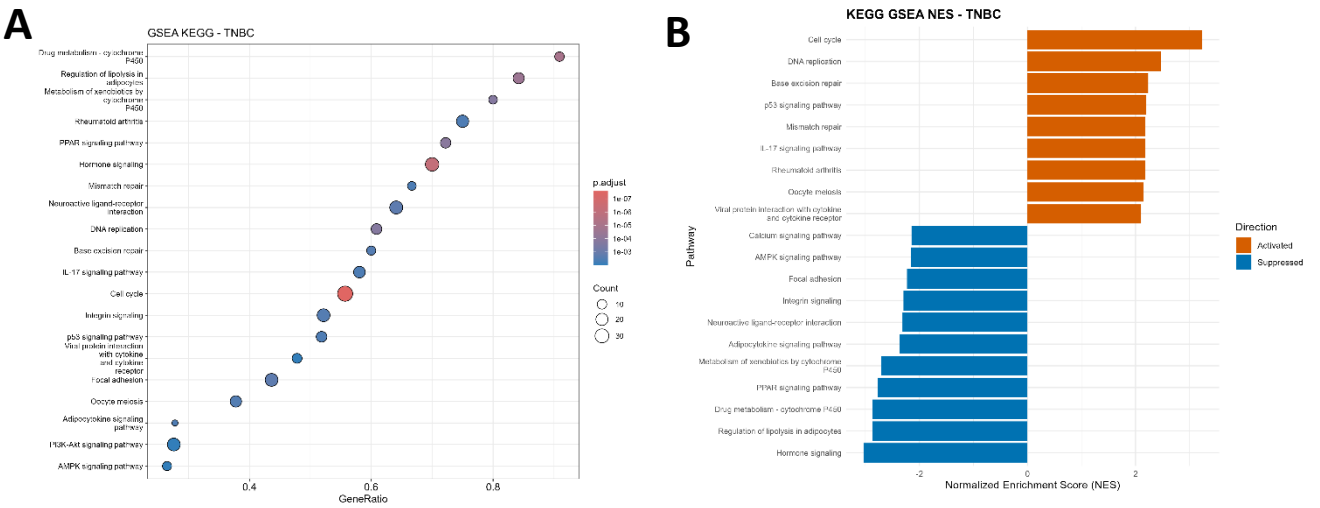

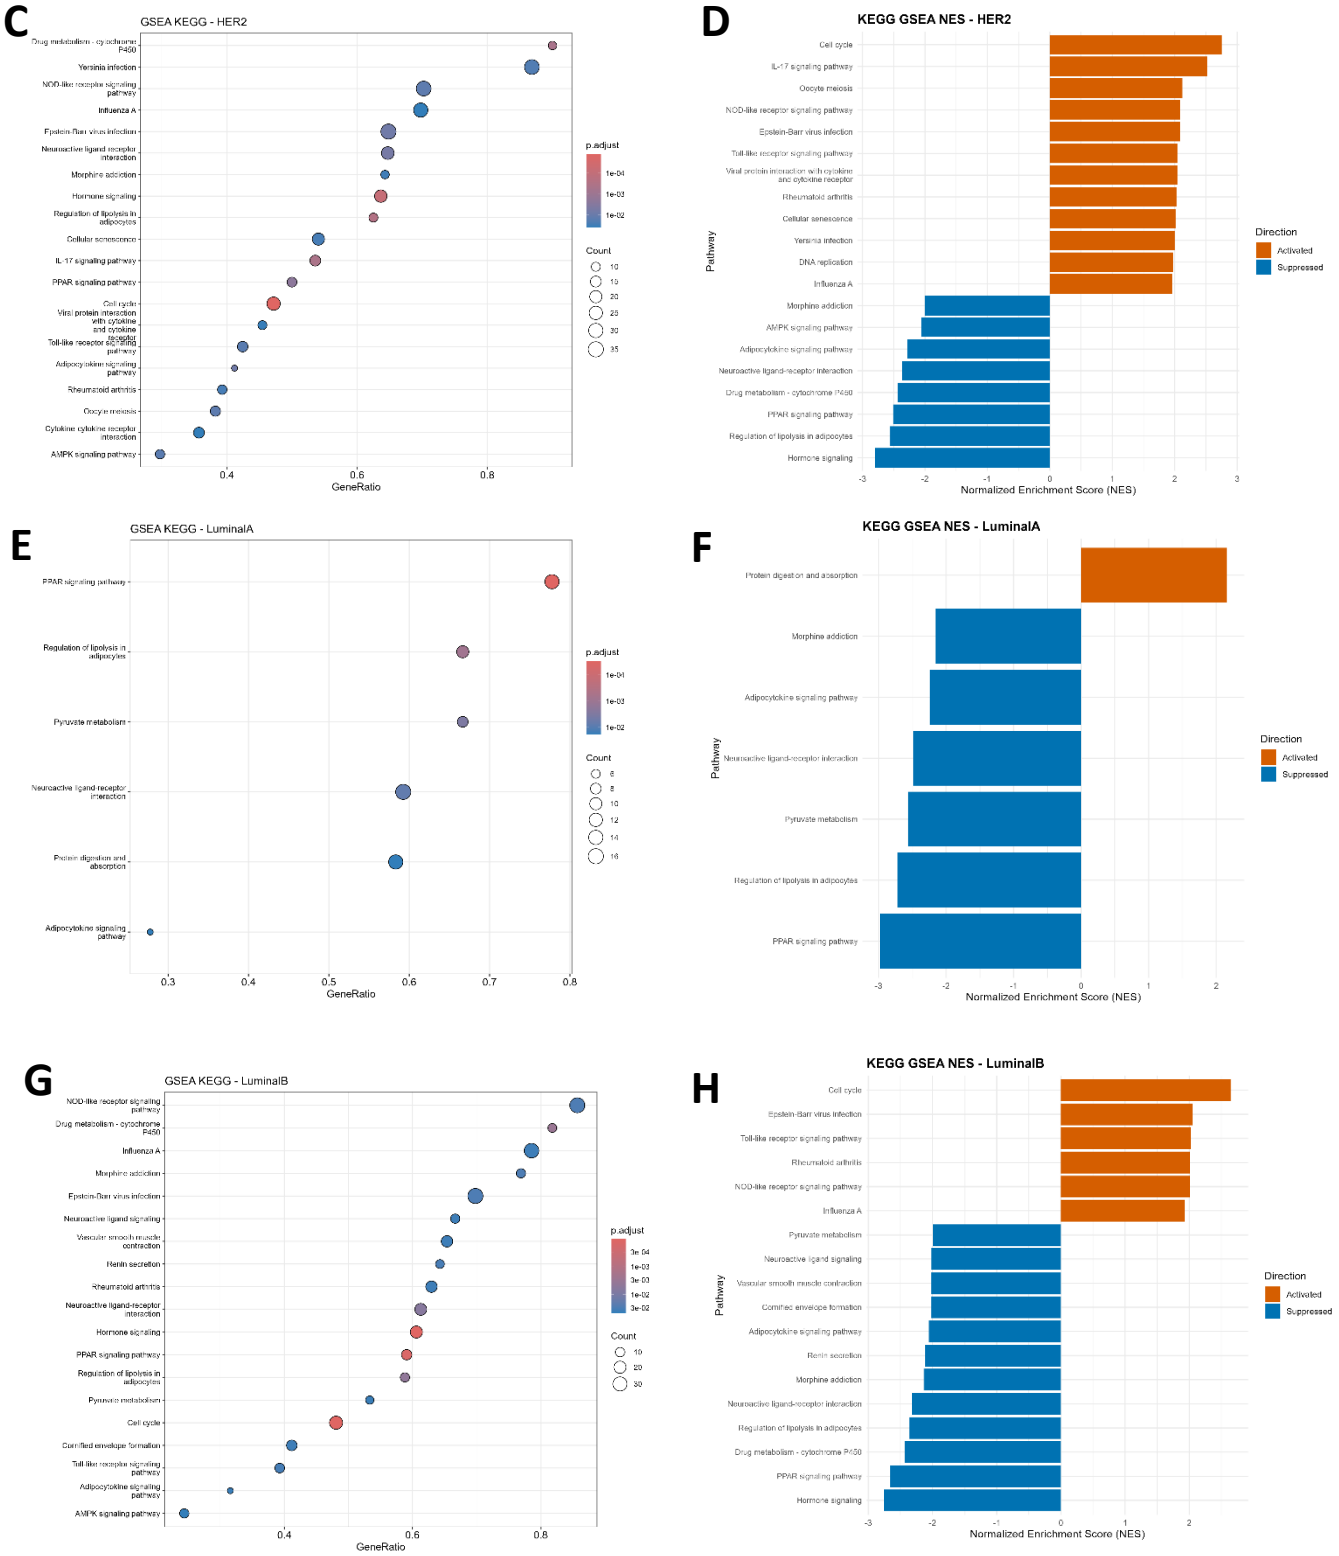

Gambar 12. Analisis GSEA KEGG pada masing masing subtipe kanker payudara

Kesimpulan

Secara keseluruhan, analisis bioinformatika pada dataset GSE65194 dan GSE45827 menunjukkan bahwa data ekspresi gen memiliki kualitas yang baik setelah proses normalisasi, yang terlihat dari distribusi nilai ekspresi gen yang relatif homogen pada boxplot dan density plot serta pola pengelompokan yang jelas antar subtipe kanker payudara pada analisis UMAP. Analisis differentially expressed genes (DEG) menunjukkan bahwa jumlah gen yang mengalami perubahan ekspresi cukup besar pada setiap subtipe, dengan jumlah gen upregulated lebih dominan dibandingkan downregulated. Subtipe TNBC/Basal menunjukkan jumlah DEG tertinggi serta jumlah gen spesifik terbanyak, menandakan bahwa subtipe ini memiliki karakteristik molekuler yang paling berbeda dibandingkan subtipe lainnya. Analisis overlap gen antara kedua dataset juga menunjukkan konsistensi yang tinggi pada masing-masing subtipe, khususnya TNBC, sehingga memperkuat reliabilitas hasil identifikasi gen diferensial yang diperoleh.

Analisis fungsional menggunakan Gene Ontology (GO) dan KEGG pathway menunjukkan bahwa gen yang mengalami upregulasi pada sebagian besar subtipe, terutama TNBC, HER2, dan Luminal B, berperan dalam proses siklus sel, pembelahan mitosis, organisasi kromosom, serta replikasi DNA, yang mencerminkan tingginya aktivitas proliferasi sel tumor. Sebaliknya, gen yang mengalami downregulasi umumnya berkaitan dengan metabolisme lipid, adhesi sel, organisasi matriks ekstraseluler, serta regulasi metabolisme energi, yang menunjukkan adanya penekanan terhadap fungsi fisiologis normal sel. Hasil ini diperkuat oleh analisis Gene Set Enrichment Analysis (GSEA) yang menunjukkan bahwa pathway yang teraktivasi pada subtipe HER2, TNBC, dan Luminal B didominasi oleh jalur cell cycle, DNA replication, chromosome segregation, dan mitotic division, sedangkan beberapa jalur metabolik seperti PPAR signaling pathway, adipocytokine signaling pathway, dan AMPK signaling pathway cenderung mengalami penekanan.

Sementara itu, subtipe Luminal A menunjukkan pola yang relatif berbeda dengan aktivitas proliferasi yang lebih rendah dan keterlibatan proses yang lebih berkaitan dengan regulasi metabolisme, organisasi matriks ekstraseluler, serta mekanisme homeostasis seluler. Secara keseluruhan, integrasi hasil DEG, analisis fungsi biologis (GO dan KEGG), serta GSEA menunjukkan bahwa perkembangan kanker payudara ditandai oleh peningkatan aktivitas jalur proliferasi dan pembelahan sel disertai perubahan regulasi metabolisme dan interaksi sel dengan lingkungan mikro tumor, dengan karakteristik molekuler yang paling menonjol pada subtipe TNBC/Basal yang menunjukkan aktivitas proliferatif paling tinggi dan profil ekspresi gen yang paling khas dibandingkan subtipe lainnya.

Keterbatasan

Keterbatasan dalam analisis ini berkaitan dengan proses identifikasi gen spesifik pada masing-masing subtipe kanker payudara. Secara metodologi, analisis ini bertujuan untuk mengidentifikasi gen yang secara khusus terkait dengan setiap subtipe melalui pendekatan perbandingan antar subtipe. Namun, dalam implementasi analisis komputasional, terdapat ketidaktepatan pada script yang digunakan dalam tahap komparatif. Script tersebut melakukan perbandingan berdasarkan keseluruhan daftar differentially expressed genes (DEG) dari masing-masing subtipe, bukan berdasarkan hasil irisan (intersection) gen yang diperoleh dari analisis Venn antar subtipe. Akibatnya, meskipun gen yang dianalisis berasal dari subtipe yang sesuai, masih terdapat kemungkinan bahwa beberapa gen yang teridentifikasi sebenarnya juga berperan dalam regulasi pada subtipe lain. Dengan demikian, gen-gen yang dihasilkan dari analisis ini belum sepenuhnya dapat dianggap sebagai gen yang benar-benar spesifik terhadap satu subtipe tertentu.